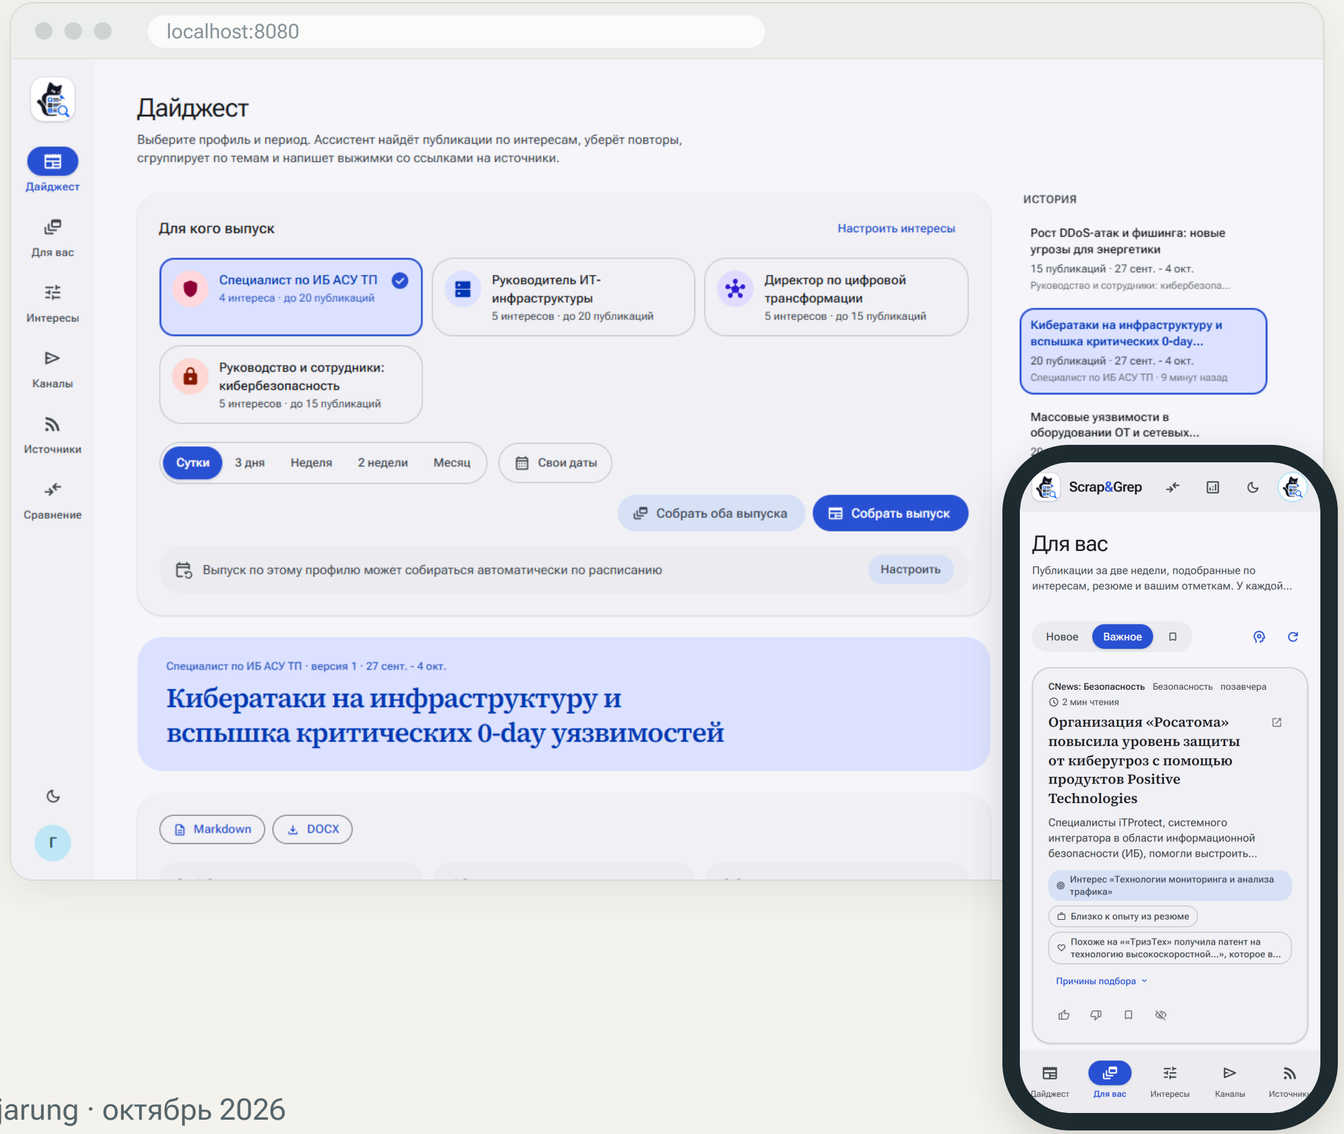
Scrap&Grep

Выпуск новостей ИБ под каждого читателя собирается за одну-четыре минуты

Сбор из 107 источников, отбор по интересам, приоритет по правилу заказчика и проверка фактов по CISA KEV и БДУ ФСТЭК. Специалисту каждый день, руководству раз в неделю.



Хакатон «ИИ-ассистенты для энергетики», полуфинал · команда misis-mojarung · октябрь 2026

ЗАДАЧА ЗАКАЗЧИКА

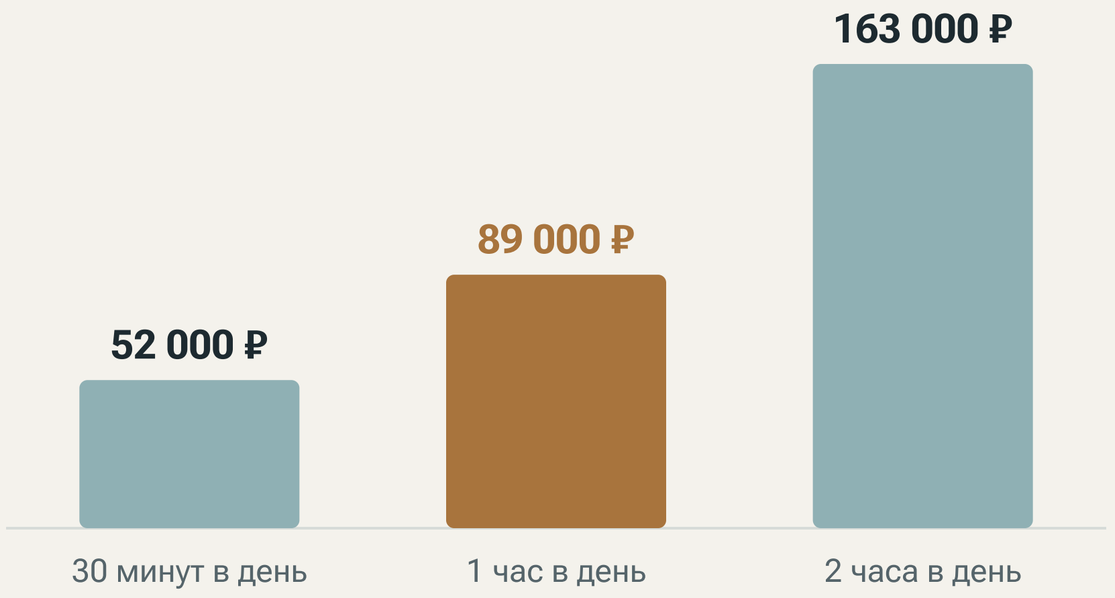
Ручной мониторинг новостей ИБ стоит команде из трёх специалистов около 89 000 ₽ в месяц

Только в списках организаторов **62** источника: 24 сайта и 18 Telegram-каналов для специалистов, 20 сайтов для руководства.

Часть сайтов не пускает бота: Cloudflare, Akamai, страницы, которые собирает скрипт.

Специалисту нужны детали каждый день, руководству выводы раз в неделю.

Полнота и приоритет зависят от того, кто читает на этой неделе: единого правила нет.



Стоимость в месяц при разном времени на мониторинг у каждого из трёх специалистов, плюс 3 часа в неделю на сводку руководству. Часы в день - допущение, пока их не замерили у аналитика.

Медиана SOC-аналитика 149 000 ₽, Хабр Карьера, I полугодие 2026; с взносами 1 170 ₽ за час. Расчёт: docs/BUSINESS.md, «Экономика».

РЕШЕНИЕ

Scrap&Grep делает каждый шаг работы аналитика сам и показывает, почему

1

Сбор

107 источников, из списков организаторов все 62. Защищённые сайты читаются лестницей способов, любой адрес добавляется из интерфейса.

2

Отбор

Профиль читателя: интересы, исключения, порог. Модель оценивает 60 кандидатов, у каждой записи и каждого отказа есть причина.

3

Приоритет

Правило заказчика: атака на энергетику и промышленность РФ выше остальных, уязвимость с эксплойтом выше. Эксплойт сверяется с CISA KEV и БДУ ФСТЭК.

4

Выпуск

Специалисту за сутки с планом на смену, руководству за неделю с выводами и брифингом голосом. Markdown и DOCX, из браузера или консоли.

Аналитик ИБ собрал те же два выпуска за ту же неделю вручную: сравнение на следующем слайде.

Аналитик собрал те же два выпуска вручную за 205 минут, ассистент за 85 секунд

Время на два выпуска, минут



Время аналитика - его собственный журнал: 75 минут на просмотр источников, по 65 минут на каждый выпуск. Ассистент: 70,5 с выпуск специалисту и 14,7 с руководству.

	Ассистент	Аналитик
Записей специалисту	20	14
Записей руководству	15	9
Общих сюжетов у специалиста	1 из 14: 0-day в Citrix NetScaler	
Общих сюжетов у руководства		0 из 9
Ссылок на источники недели	все	8 из 36

Аналитик нашёл регуляторику и право (приказы ФСТЭК № 137 и ФСБ № 297, профстандарт по КИИ, оборотные штрафы) и MikroTik с предписанием ГРЧЦ; ассистент - бюллетени CISA ICS по оборудованию АСУ ТП, 17 уязвимостей в российской SCADA и проверку эксплойтов по CISA KEV и БДУ.

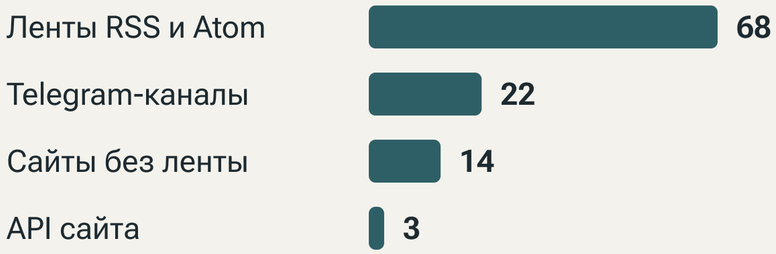
Чей отбор полнее, покажут оценка кандидатов человеком и слепое сравнение выпусков: они ещё не проведены, поэтому цифр полноты против человека не приводим.

docs/eval/vs-analyst.md; ответ аналитика целиком - examples/vs-analyst.

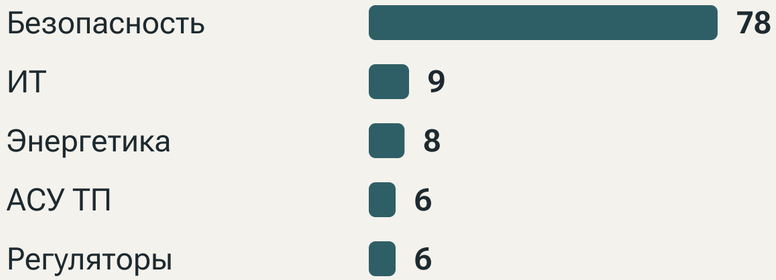
КРИТЕРИЙ 1 · РЕПРЕЗЕНТАТИВНОСТЬ МАТЕРИАЛОВ

Каталог покрывает все 62 источника из списков организаторов и ещё 45 сверх них

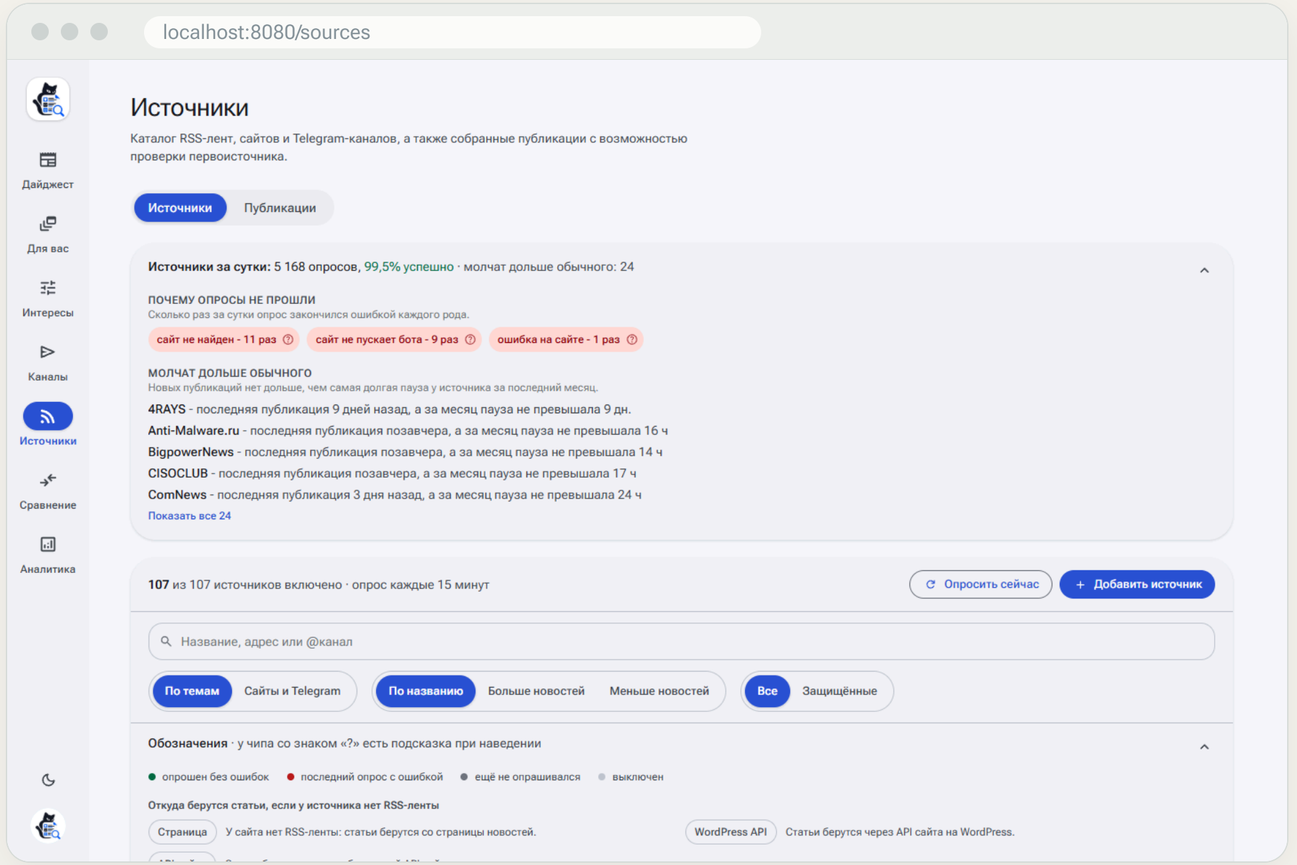
107 источников по виду



по теме



1 737 публикаций за неделю 25.09-02.10. Стек приходит со снимком из **2 109** реальных публикаций и работает без интернета.



Каждый источник опрашивается раз в 15 минут; здоровье за сутки и способ чтения видны в каталоге.

КРИТЕРИЙ 1 · РЕПРЕЗЕНТАТИВНОСТЬ МАТЕРИАЛОВ

На 21 примере организаторов тип записи совпал в 6 случаях из 6, приоритет в 4 из 6

Каждый пример датасета прогнан через те же шаги, что запись выпуска, и положен рядом с желаемым выводом.

Что сравнивали	Результат	Где расходимся и почему
Специалисты: атаки и уязвимости	тип 6 из 6, приоритет 4 из 6	у specialist-4 в датасете чужой CVE (уязвимость WSUS из specialist-7), у specialist-3 страной жертвы названа РФ при атаке на Европу и Азию
Специалисты: посты Telegram	тип по содержанию	датасет кладёт пост в «Инфо» по источнику; Scrap&Grep даёт посту об уязвимости карточку уязвимости и ссылки из поста, как в желаемом выводе
Руководство: двенадцать признаков датасета	22 из 32, лишних 13	по каждому из 11 примеров видно, какой признак совпал, какой пропущен и какой поставлен сверх датасета
Чтение страниц примеров	19 из 21	два сайта ответили HTTP 202 и 401

Ещё в репозитории: выпуски для четырёх профилей в Markdown и DOCX и три сценария смены интересов с разбором, что пришло и что ушло.

examples/dataset/README.md; examples/README.md

КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

Стек поднимается одной командой: один образ бэкенда в шести ролях и граф сборки с чекпоинтами

СБОР

worker-ingest
RSS, t.me/s, страницы, лестница чтения, эмбеддинги новых статей

browser, FlareSolverr
для сайтов, которые не пускают бота

ХРАНЕНИЕ

PostgreSQL 18
статьи, pgvector и полнотекстовый поиск, чекпоинты графа

Valkey
очереди задач, кеш ответов модели, прогресс

ClickHouse
события показов и отметок

СБОРКА И МОДЕЛЬ

worker-digest
граф LangGraph, до 4 запросов к модели параллельно

Ollama или OpenAI-совместимый API
оценки и тексты; эмбеддинги embeddinggemma локально

worker-profile, worker-media
резюме и вкус читателя; брифинг и короткие видео

ДОСТУП

web (Caddy) и api (FastAPI)
интерфейс, REST, прогресс по SSE, MCP

cli
выпуск в Markdown и DOCX одной командой

scheduler
опрос раз в 15 минут, выпуски по расписанию

Граф сборки выпуска

prepare профиль и период › **retrieve** поиск по смыслу и словам › **grade** веер: задача на кандидата › **select** порог, лимит, исключения › **cluster** склейка повторов, темы › **summarize** веер: задача на статью › **compose** разделы, «Главное» › **persist** запись выпуска

Упавший воркер продолжает с прерванного шага: чекпоинты в PostgreSQL. docs/ARCHITECTURE.md, «Компоненты» и «Граф сборки».

КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

Сайт, который не пускает бота, читается следующей ступенью лестницы

1

Обычный запрос

SecurityLab, Habr: **0,2-0,7 с**

2

Заголовки браузера

для сайтов, которым хватает User-Agent браузера; среди защищённых сайтов списка таких не нашлось

3

Отпечаток Chrome

Cloudflare с 403 и заглушкой: Dark Reading **0,9 с**, Cybernews **1,0 с**, SecurityWeek **1,4 с**, Netskope **4,2 с**

4

Браузер в стеке, FlareSolverr

проверка Cloudflare с JS: **15,9 с**; БДУ АСУ ТП, которую собирает скрипт

Прокси

Общий, свой у источника или пулом с ротацией при 403 и 429.

Видно у источника

Ступень и причина записываются: «Шаг «обычный запрос» не сработал (403), сработал «отпечаток Chrome»».

Безопасно

Защита от SSRF на каждой ступени: внутренние адреса не читаются.

Замеры 2 октября 2026 года, без прокси. docs/DECISIONS.md, «Сбор: лестница способов чтения».

КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

Каждая запись сверяется с текстом статьи и с базами уязвимостей

Сбор — полный текст со страницы, если в ленте анонс

›

Поиск — по смыслу и по словам для каждого интереса

›

Оценка — 60 кандидатов по шкале 0-3 с причиной

›

Склейка — пересказы одной новости становятся одной записью

›

Запись — тип, карточка, приоритет, «почему важно»

›

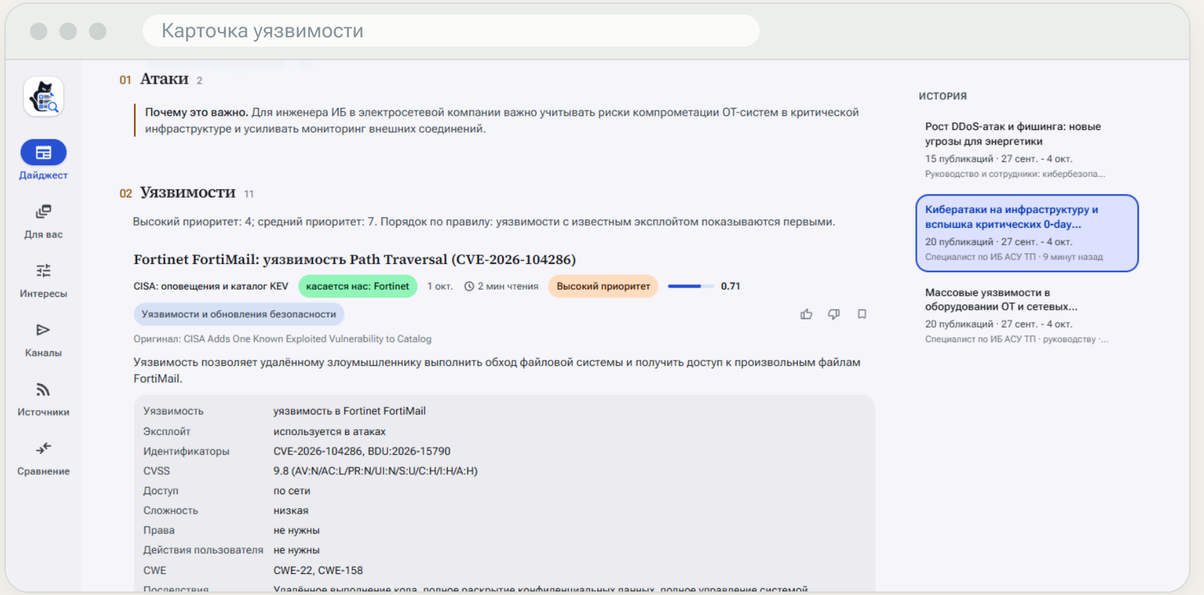
Проверка — чего нет в статье, нет в карточке; номера по CISA KEV и БДУ

›

Выпуск — Markdown с оглавлением, DOCX, история

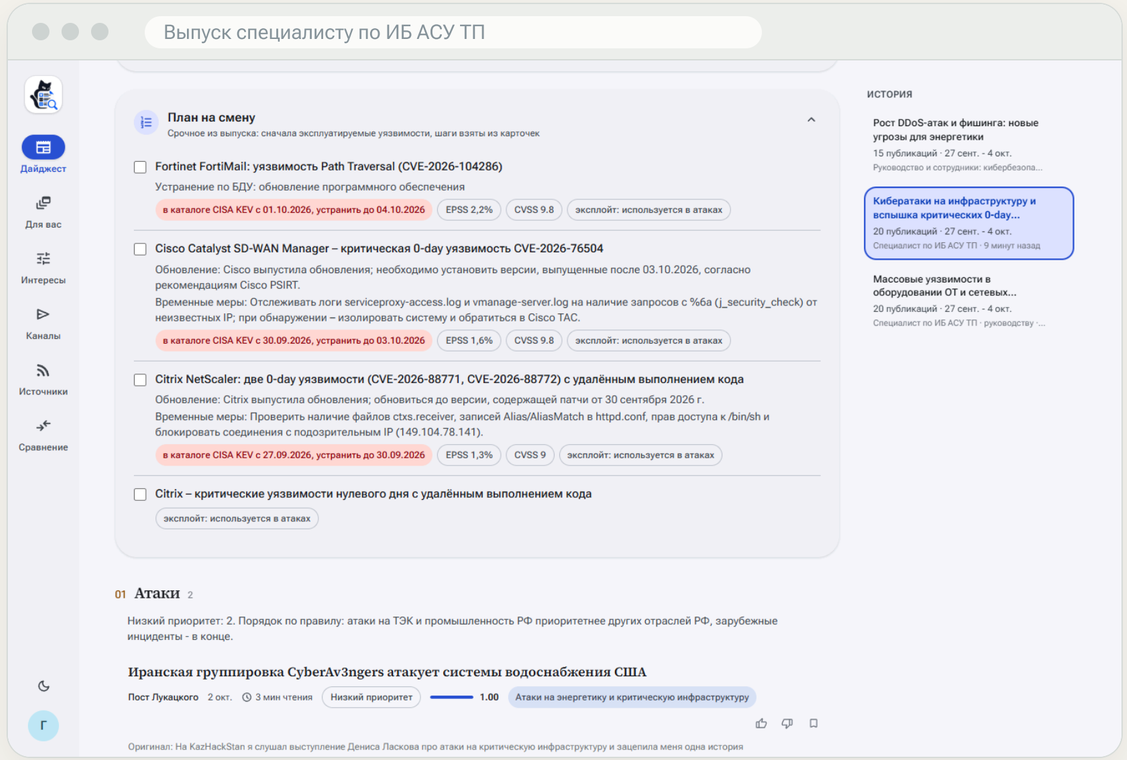
Модель сама вызывает инструмент `lookup_vulnerability`: CISA KEV, БДУ ФСТЭК, NVD, EPSS и Exploit-DB по локальным копиям. Номера, о которых она не спросила, граф проверяет сам.

Сборка - граф LangGraph с чекпоинтами: упавший воркер продолжает с прерванного шага. Ответы модели кешируются, повторная сборка по тому же профилю занимает секунды.

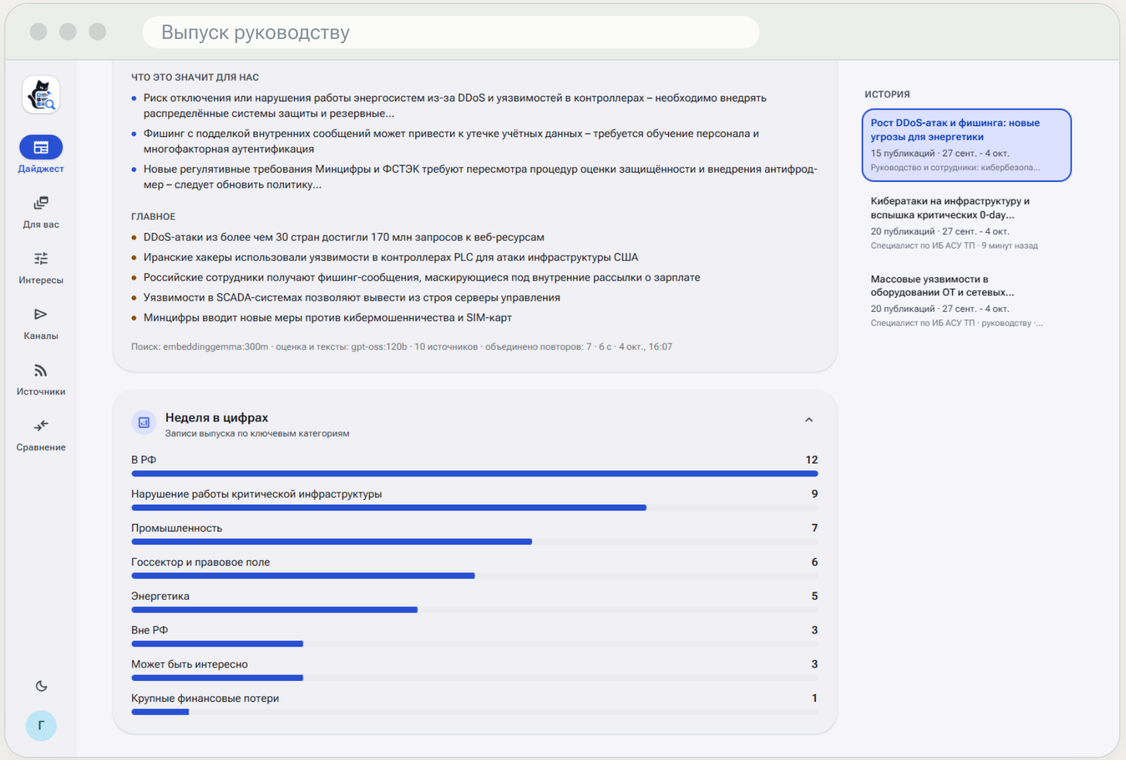


КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

Специалист получает план на смену каждый день, руководство выводы раз в неделю

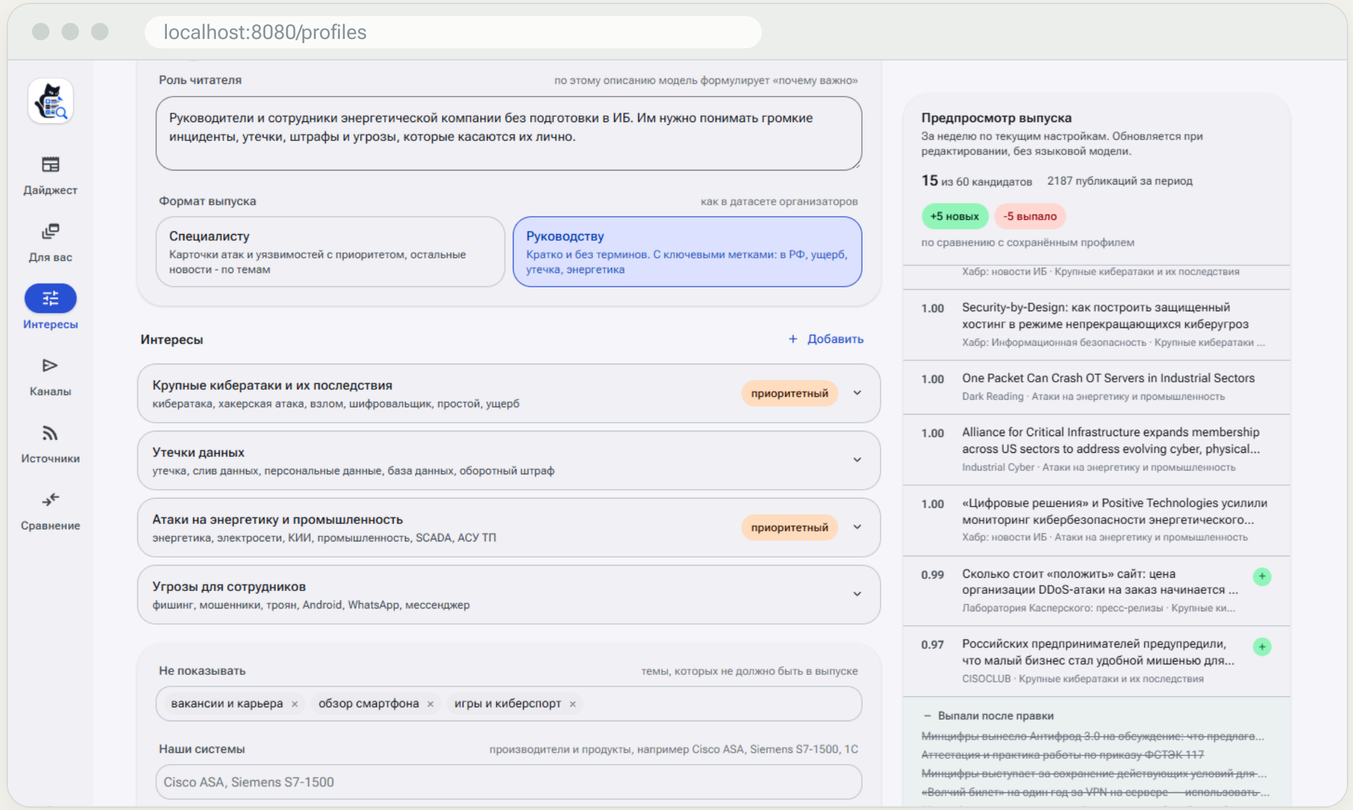


Сначала план на смену: срочные уязвимости и атаки с галочками, что обновить и какие индикаторы искать. Записи о продуктах из «Наших систем» помечены «касается нас».



«Что это значит для нас», период в цифрах против прошлого выпуска, записи в одно-два предложения без номеров CVE и брифинг голосом на две минуты.

Правка интересов сразу меняет подборку, и это видно ещё до сборки



examples/change

Три сценария на одной неделе, выпуск специалисту

Убран интерес «Уязвимости»

20 записей до и после: пришло 9, ушло 9.

Исключение «уязвимости Citrix»

Пришло 3, ушло 3; обе записи о Citrix ушли с причиной.

Порог 0,50 → 0,70, размер 20 → 10

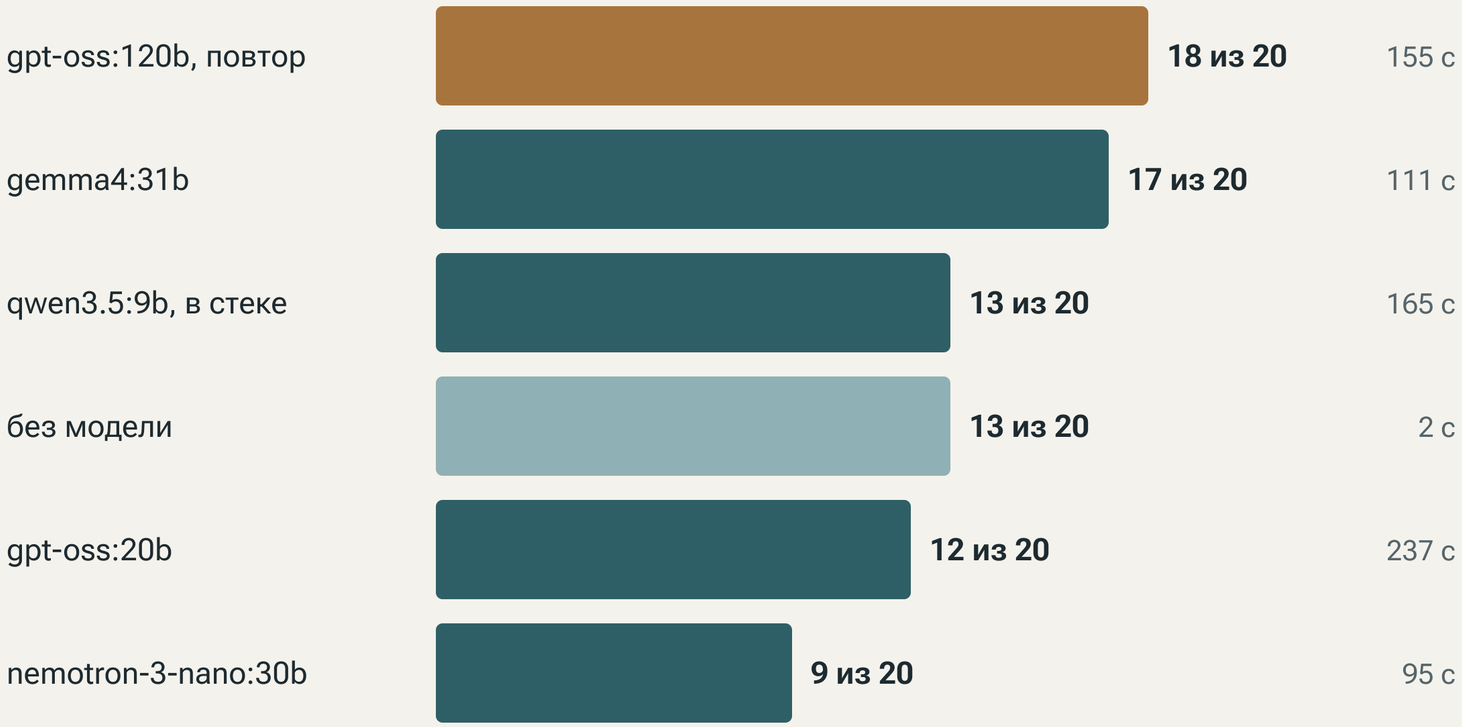
Ушедшие вытеснены более сильными, у каждой её оценка.

Предпросмотр работает без языковой модели, «Сравнение» показывает два выпуска рядом.

КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

Модель меняется одной строкой в .env, сценарий выпуска держится на всех

Записей, совпавших с первым прогоном gpt-oss:120b, из 20, и время сборки



Разделы, карточки, приоритеты и проверка работают на всех моделях и без модели.

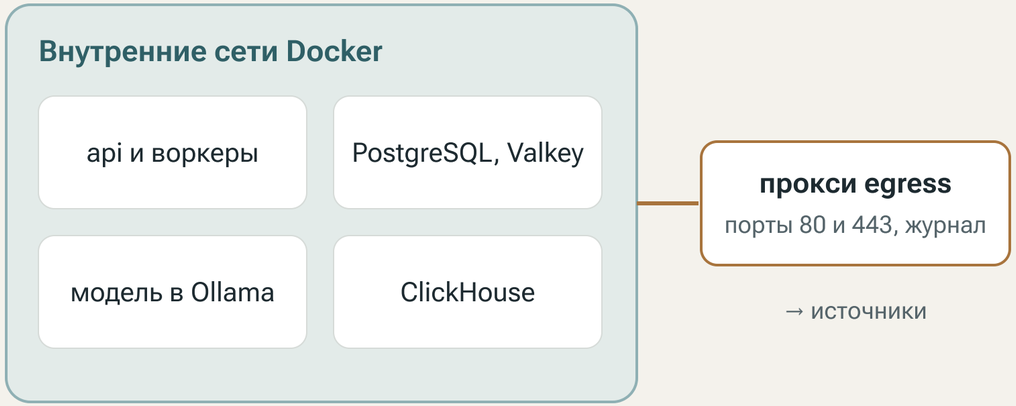
Два прогона одной gpt-oss:120b совпадают в 18 записях из 20: это шум самой модели.

Поддерживаются Ollama и любой OpenAI-совместимый API: Yandex AI Studio, vLLM. По умолчанию в режиме с моделью - локальная Qwen3.6 35B-A3B.

Выпуск специалисту по ИБ АСУ ТП за неделю примеров: 60 кандидатов, 20 записей. examples/models/README.md

КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

Стек работает в закрытом контуре, наружу ходит только загрузчик источников



`offline_bundle.sh save`: 7 образов ядра 4,7 ГБ и модели 1,6 ГБ за 4 мин 21 с. `load` в пустой каталог за 3 мин 29 с, копия поднялась без сети и прошла проверочный сценарий.

Своя видеокарта для gpt-oss-120b: опубликованные замеры при 1-4 запросах и расчёт выпуска

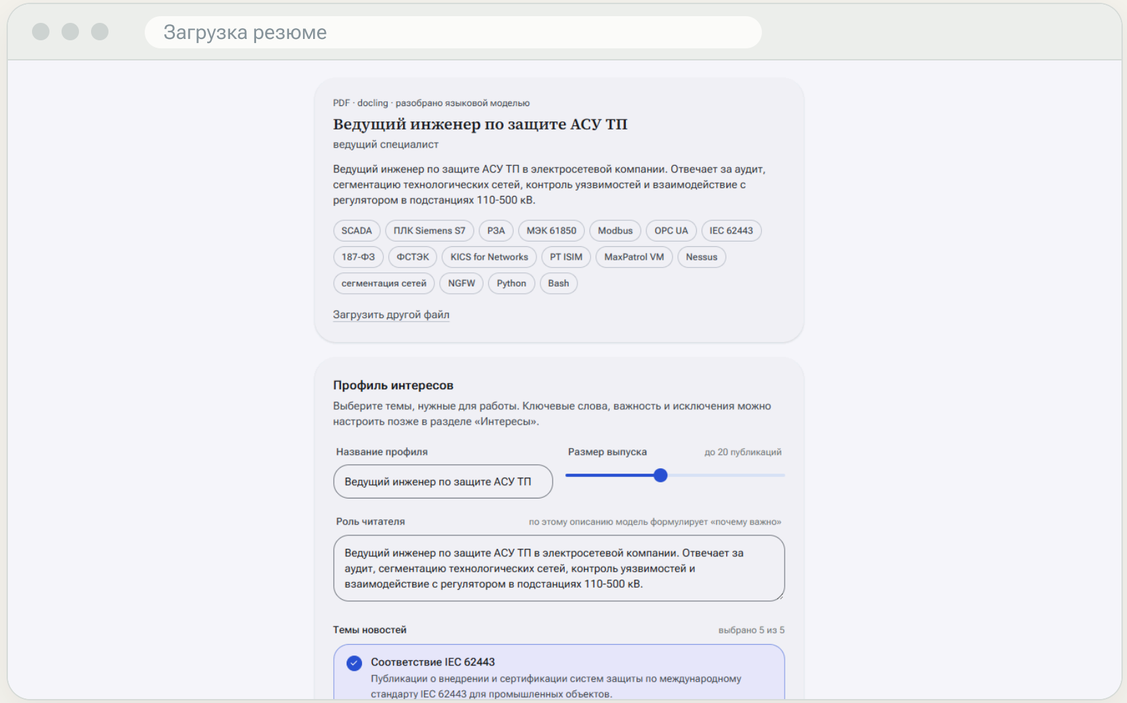
Карта и движок	Генерация, ток/с	Выпуск	Выпусков в час
H100 80 ГБ, vLLM	233 / 511	≈45 с	≈80
RTX PRO 6000 96 ГБ, vLLM	181 / 361	≈56 с	≈64
A100 80 ГБ, vLLM 0.11	- / 326	≈70 с	≈50
DGX Spark 128 ГБ, SGLang	51 / 92	≈4,3 мин	≈14

Генерация: один запрос / четыре сразу. Выпуск специалисту - 110 обращений, 166 511 токенов на вход и 16 127 на выход; время = вход / обработка запроса + выход / генерация при четырёх. Модель в MXFP4 помещается на одну карту 80 ГБ; аренда H100 - $4,29 в час, A100 - $1,99 (Lambda, 04.10.2026).

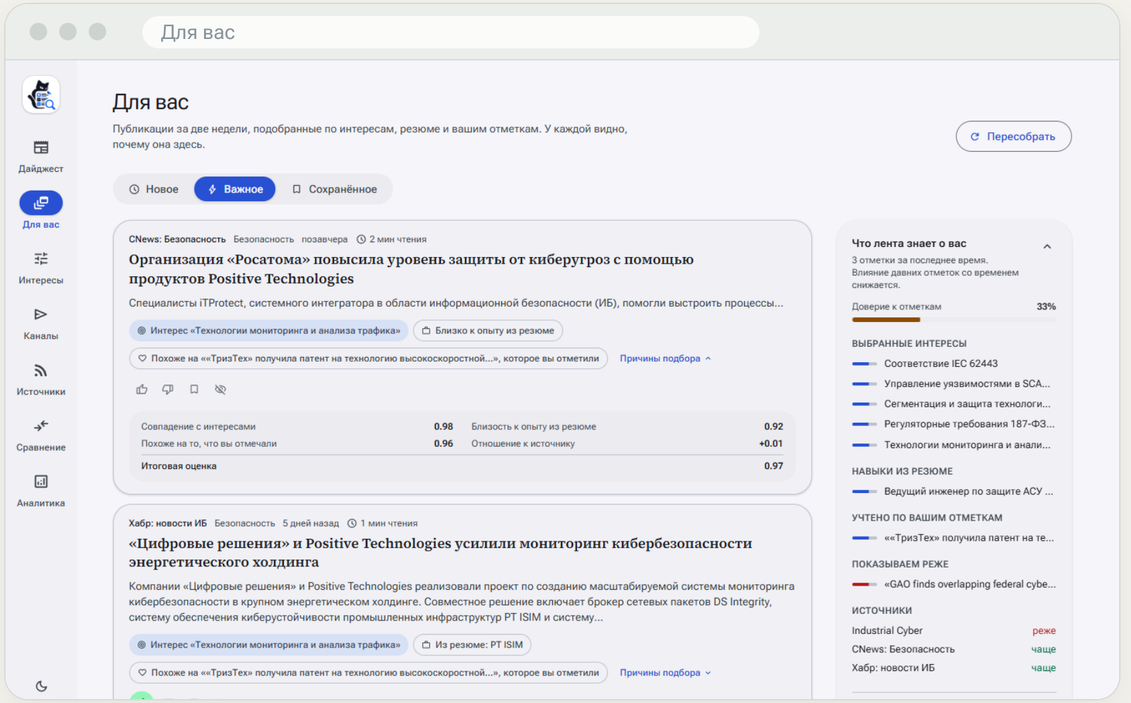
README, «Закрытый контур» и «Требования к железу»; millstoneai.com/inference-benchmark, 02.2026 (H100, RTX PRO 6000); docs.gpustack.ai, performance-lab (A100); lmsys.org, 10.2025 (DGX Spark); arxiv 2508.10925.

КРИТЕРИЙ 2 · ПЕРСОНАЛИЗАЦИЯ

Резюме задаёт профиль с первой минуты, и лента сразу подбирается под специалиста



Должность, навыки и предложенные темы. Имя и контакты вырезаются до анализа, файл удаляется сразу после разбора; сканы читает docling.



У каждой статьи видно, почему она здесь: интерес, опыт из резюме, похожее на то, что читатель отметил; «Причины подбора» раскладывают оценку на части.

КРИТЕРИЙ 2 · РЕКОМЕНДАТЕЛЬНАЯ СИСТЕМА

Своя рекомендательная модель строит ленту по вкусу читателя и учится на его отметках

1. Кандидаты
один SQL-запрос: близость статей за две недели к каждой грани вкуса по эмбеддингам pgvector и ключевым словам

2. Оценка
грани с доверием: интерес 0,45, резюме 0,10, выученная по лайкам до 0,35, избегаемая вычитается; плюс свежесть, источник, «нравится коллегам»

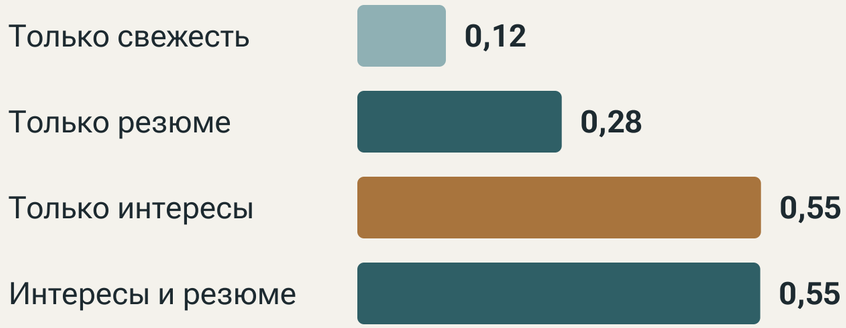
3. Перестановка
копии одной истории выбрасываются, серии одного источника разбиваются, каждое седьмое место - «Что-то новое»

4. Обучение
ночью LightGBM LambdaRank на показах и отметках из ClickHouse с поправкой на место в списке

Каждая карточка объясняет оценку: какой интерес совпал, что из резюме, на что похоже из отмеченного. Отметки весят по-разному (закладка 1,2, лайк 1,0, открытие 0,4, дизлайк -1,0) и слабеют вдвое за три недели.

LightGBM заменяет ручные веса, только если на трёх последних днях поднимает nDCG@20 больше чем на 0,01; половина читателей остаётся контрольной группой. На симуляции из 200 читателей модель проиграла (0,758 против 0,789 по кликам), и проверка её не включила.

nDCG@20 ленты специалиста по ИБ АСУ ТП до первых отметок

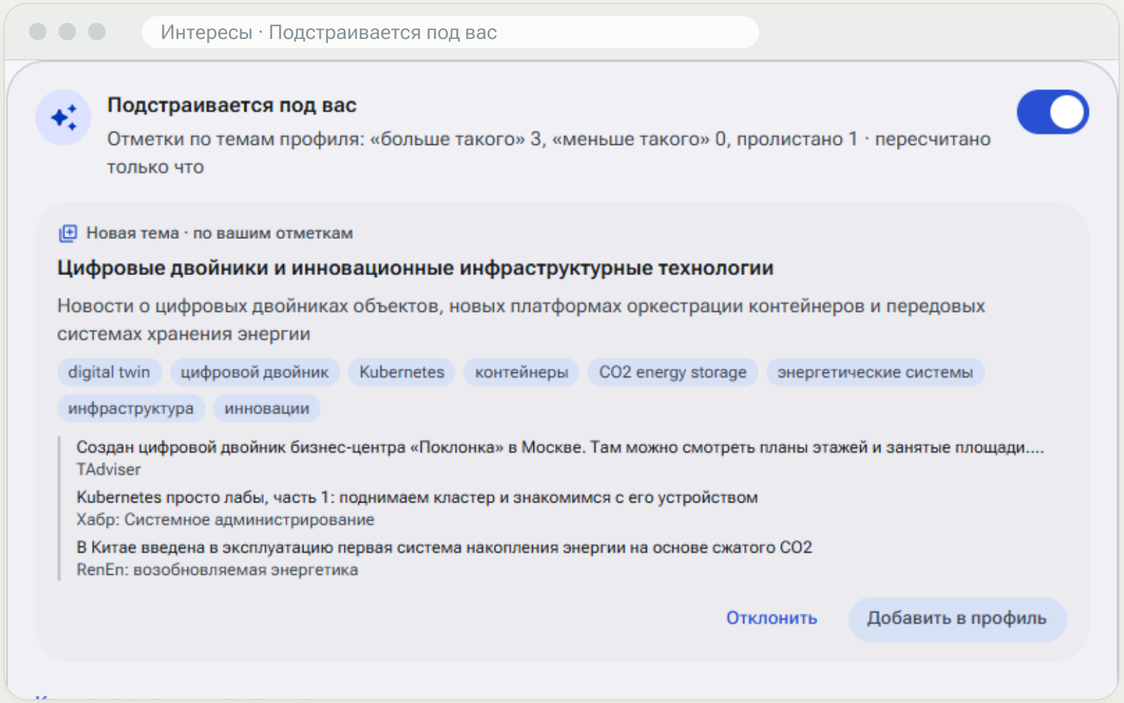


Интересы дают главный прирост, резюме помогает, пока интересов нет. Неделя из 871 статьи.

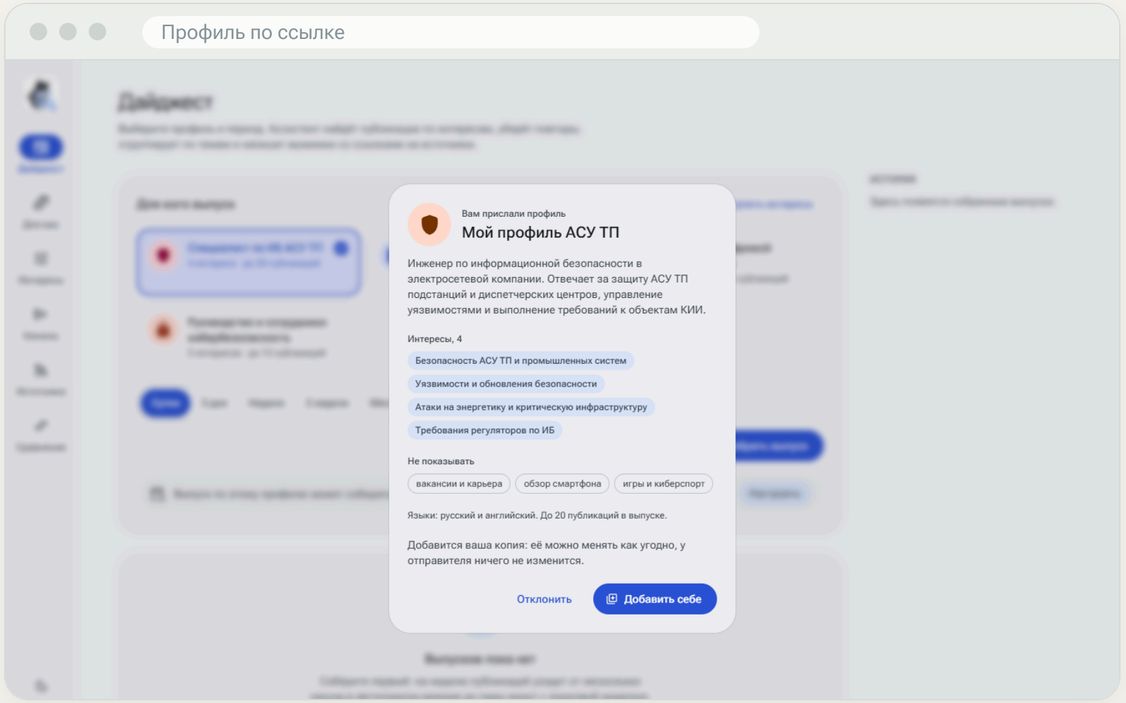
docs/ARCHITECTURE.md, «Персональная лента» и «Обучаемое ранжирование»; DECISIONS.md, «Обучаемое ранжирование»; docs/eval/recsys.md, docs/eval/ranker.md.

КРИТЕРИЙ 2 · ПЕРСОНАЛИЗАЦИЯ

Профиль учится на отметках читателя и передаётся коллеге по ссылке



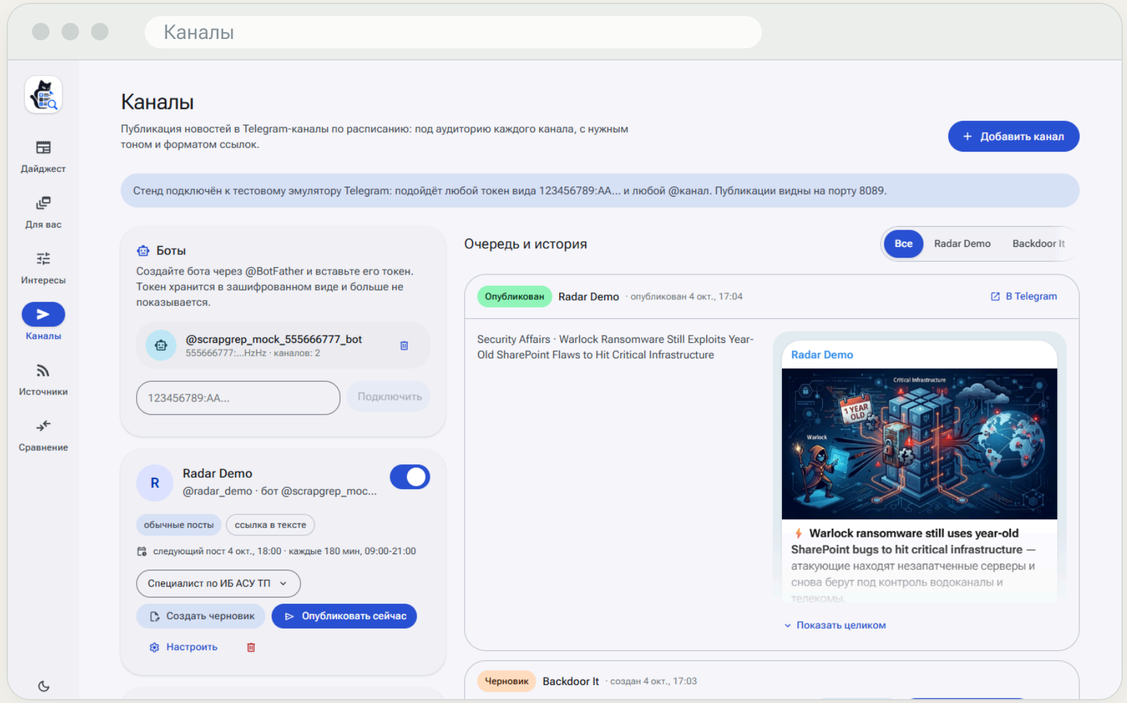
Вес интереса растёт от «больше такого» и падает от «меньше такого», не больше чем на 10%; новая тема предлагается по статьям, которые профиль сам не нашёл. Сохранённый профиль при этом не меняется.



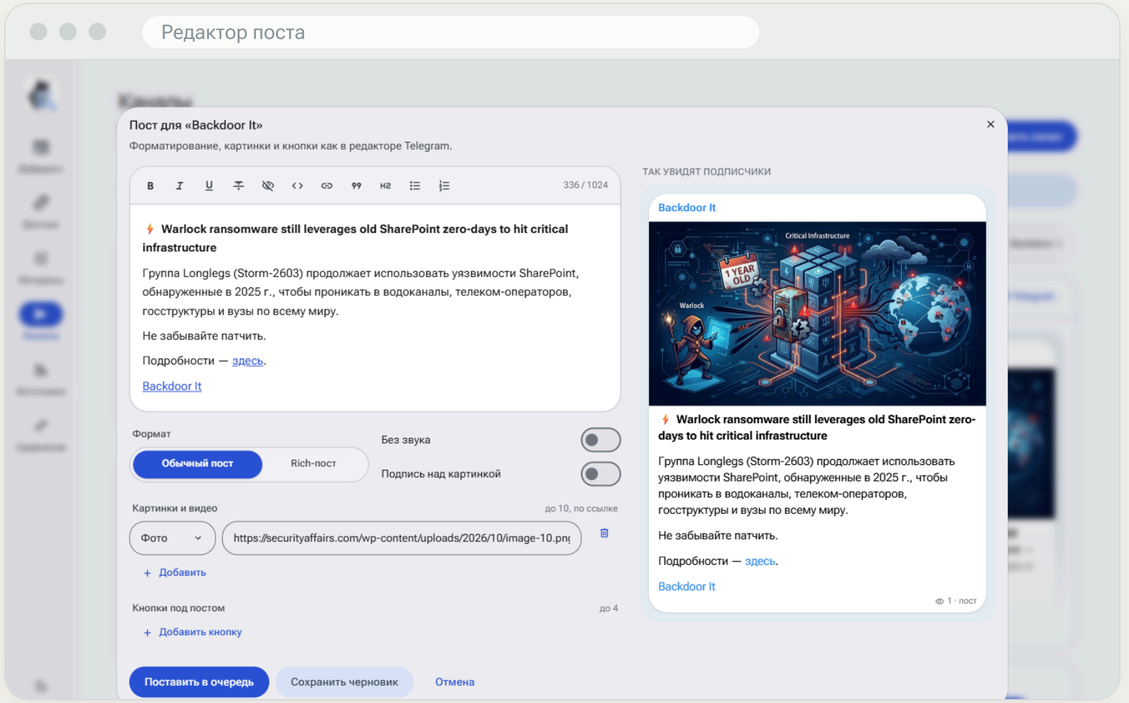
Коллега открывает ссылку и добавляет копию профиля себе. Выпуски, отметки и резюме владельца по ссылке не видны.

КРИТЕРИЙ 3 · БИЗНЕС-ОРИЕНТИРОВАННОСТЬ

Боты публикуют новости в Telegram-каналы компании под аудиторию каждого канала

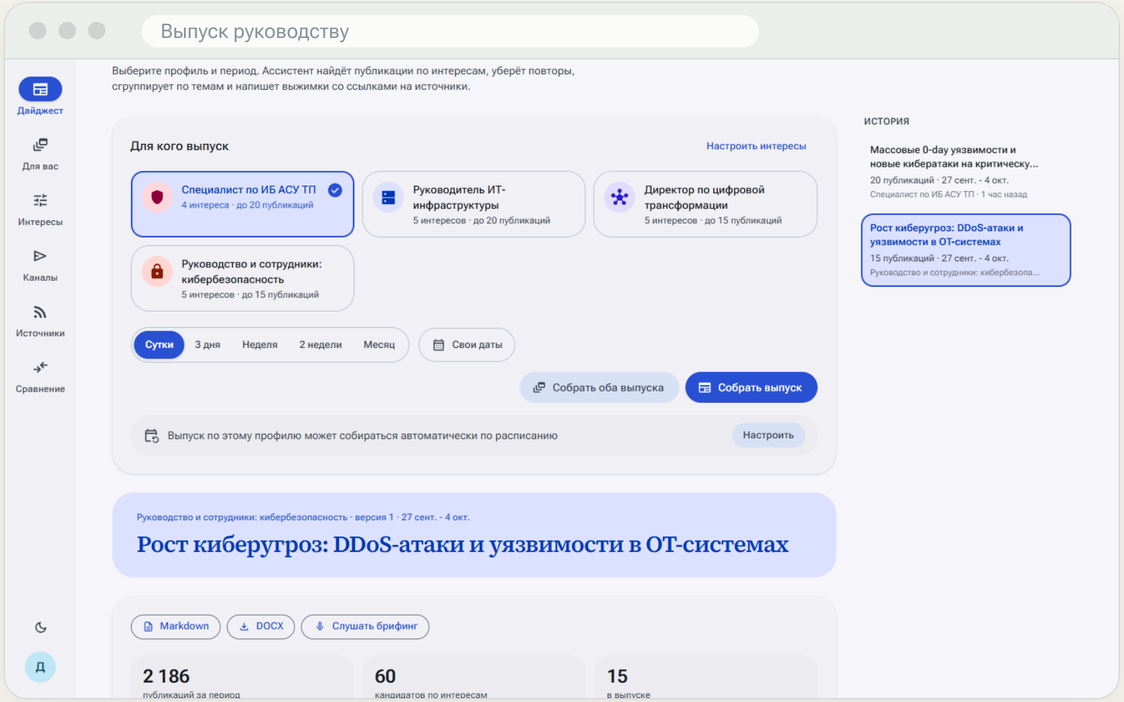


У каждого канала свой профиль отбора, тон, подача ссылок и расписание; пост можно опубликовать сразу или отправить черновиком на проверку.

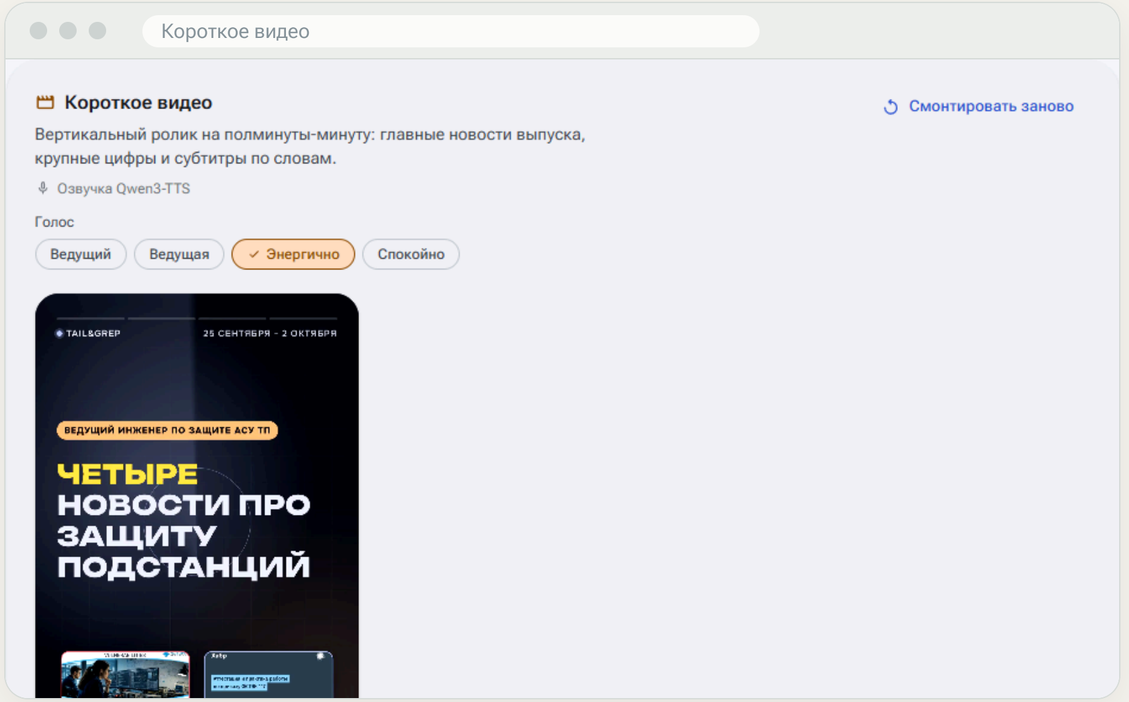


Редактор с форматированием, картинкой, кнопками и предпросмотром, как пост покажет Telegram. На стенде посты уходят в эмулятор Bot API.

Руководитель слушает выпуск за две минуты, а из выпуска собирается короткое видео



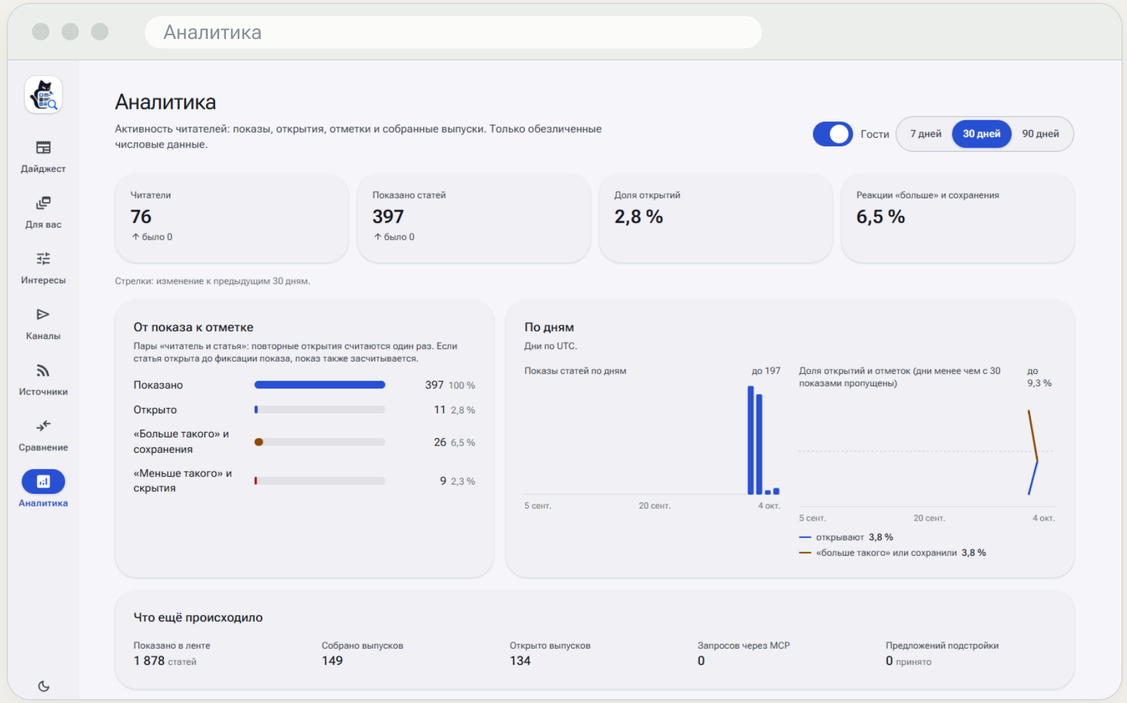
«Слушать брифинг» пересказывает выпуск голосом примерно за две минуты: что период значит для компании и главные записи, без номеров уязвимостей и адресов.



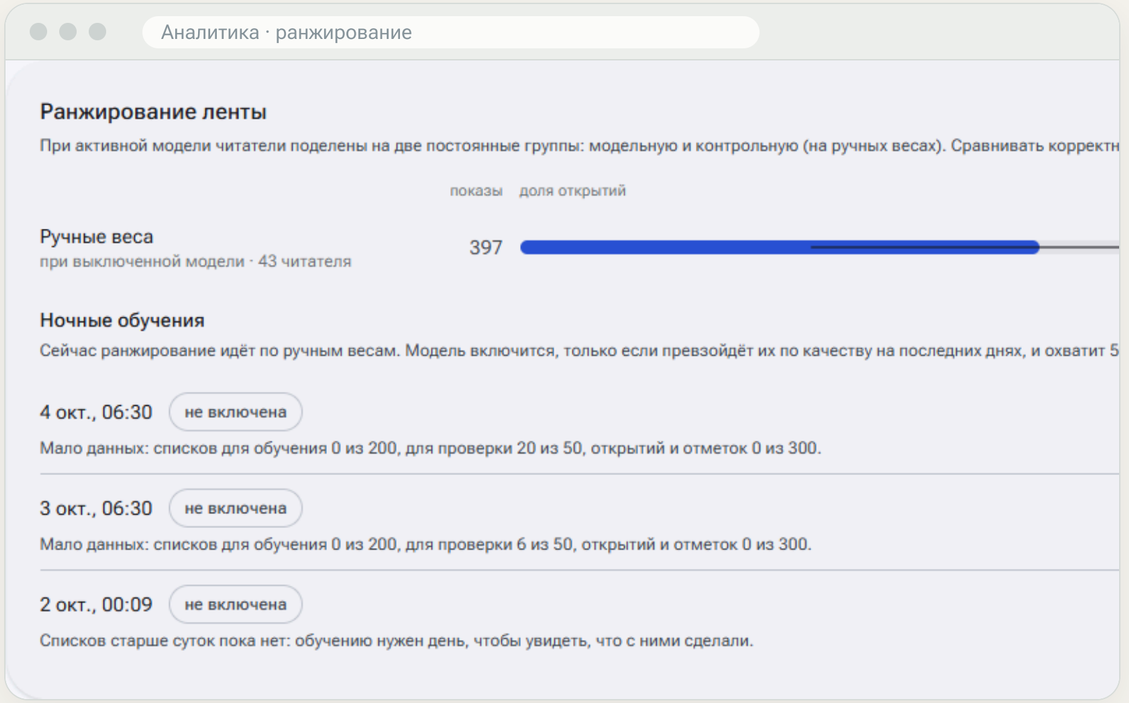
Вертикальный ролик на полминуты-минуту с субтитрами по словам и озвучкой одним из четырёх голосов. Ролик в кадре собран 2 октября, до смены названия продукта.

КРИТЕРИЙ 3 · БИЗНЕС-ОРИЕНТИРОВАННОСТЬ

Аналитика показывает, что сотрудники видят, открывают и отмечают

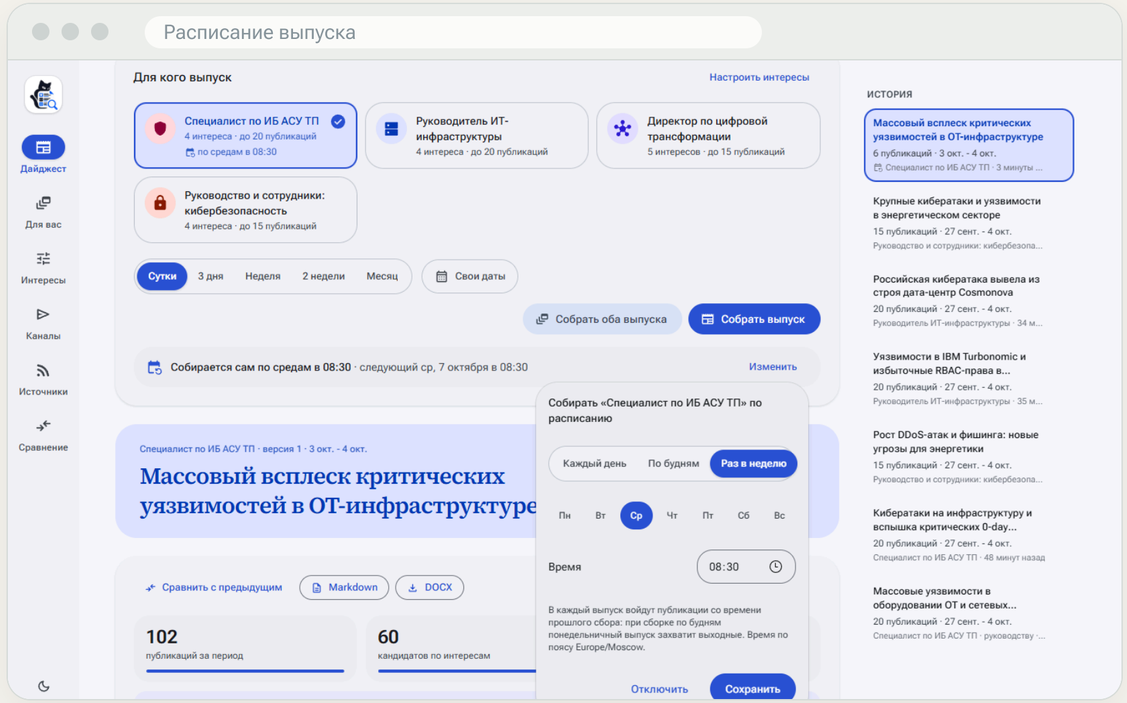


Читатели, доли открытий и отметок, воронка от показа к отметке и дни. Только числа, без текстов и адресов; раздел видит администратор.

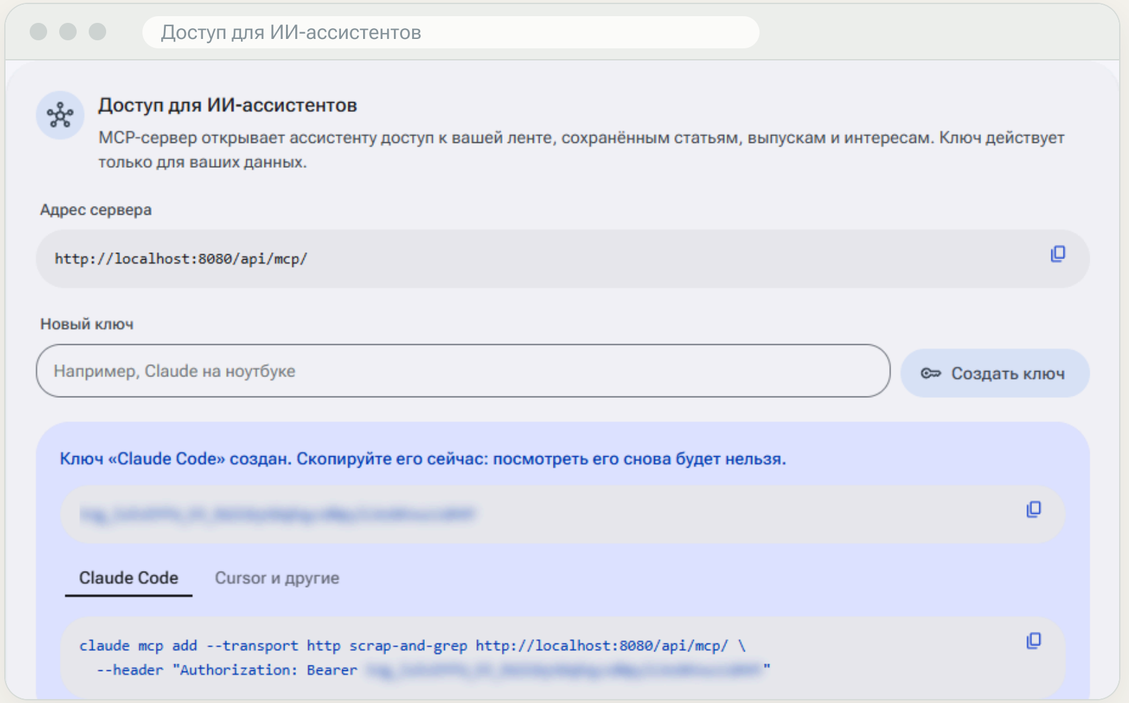


Доли по местам в ленте с доверительным интервалом и ночные обучения модели. Те же события - метрики пилота: время до обзора, открытия, отметки.

Выпуск приходит по расписанию, а ИИ-ассистент сотрудника читает его новости по личному ключу



Каждый день, по будням или раз в неделю, в местное время читателя. Специалисту по умолчанию сутки, руководству неделя.



MCP-сервер отдаёт Claude, Cursor и другим клиентам ленту, сохранённое, выпуски и интересы только этого читателя. Ключ показывается один раз.

КРИТЕРИЙ 3 · БИЗНЕС-ОРИЕНТИРОВАННОСТЬ

С ассистентом мониторинг обходится команде в 28 700 ₽ вместо 89 000 ₽ в месяц



60 600 ₽

экономии в месяц на команду из трёх специалистов, **0,73 млн ₽** в год

Выпуск специалисту: 166 511 токенов на вход и 16 127 на выход, около 2,9 ₽. Руководству около 1,9 ₽.

Чтение выпуска остаётся у человека: 15 минут в день заложены в расчёт.

Хабр Карьера; тарифы Ollama на 03.10.2026; курс ЦБ 83,48 ₽; Selectel. docs/BUSINESS.md, «Экономика».

ВНЕДРЕНИЕ

Пилот на 4 недели проверит главное число: полноту выпуска против аналитика

Установка

Закрытый контур: образы, веса модели, корпоративный прокси, проверочный сценарий. 10-20 сотрудников из разных групп, у каждого свой профиль.

Что измеряем

Время до готового обзора, полнота против ручной подборки, доля открытых записей и отметок по неделям. События уже пишутся в ClickHouse.

Успех

Полнота выпуска не ниже 90% от того, что нашёл аналитик, при проверке выпуска не дольше 15 минут в день.

Попробовать

```
docker compose up -d --build
```

Интерфейс на localhost:8080, экрана входа нет.

```
docker compose run --rm cli digest
```

Оба выпуска в Markdown и DOCX в папке out/.

Репозиторий: git.codenrock.com/codenrock/ii-assistenty/misis-mojarung/assistent-dlya-sozdaniya-it-ib-daydzhestov

docs/BUSINESS.md, «Пилот»; README, «Быстрый запуск».