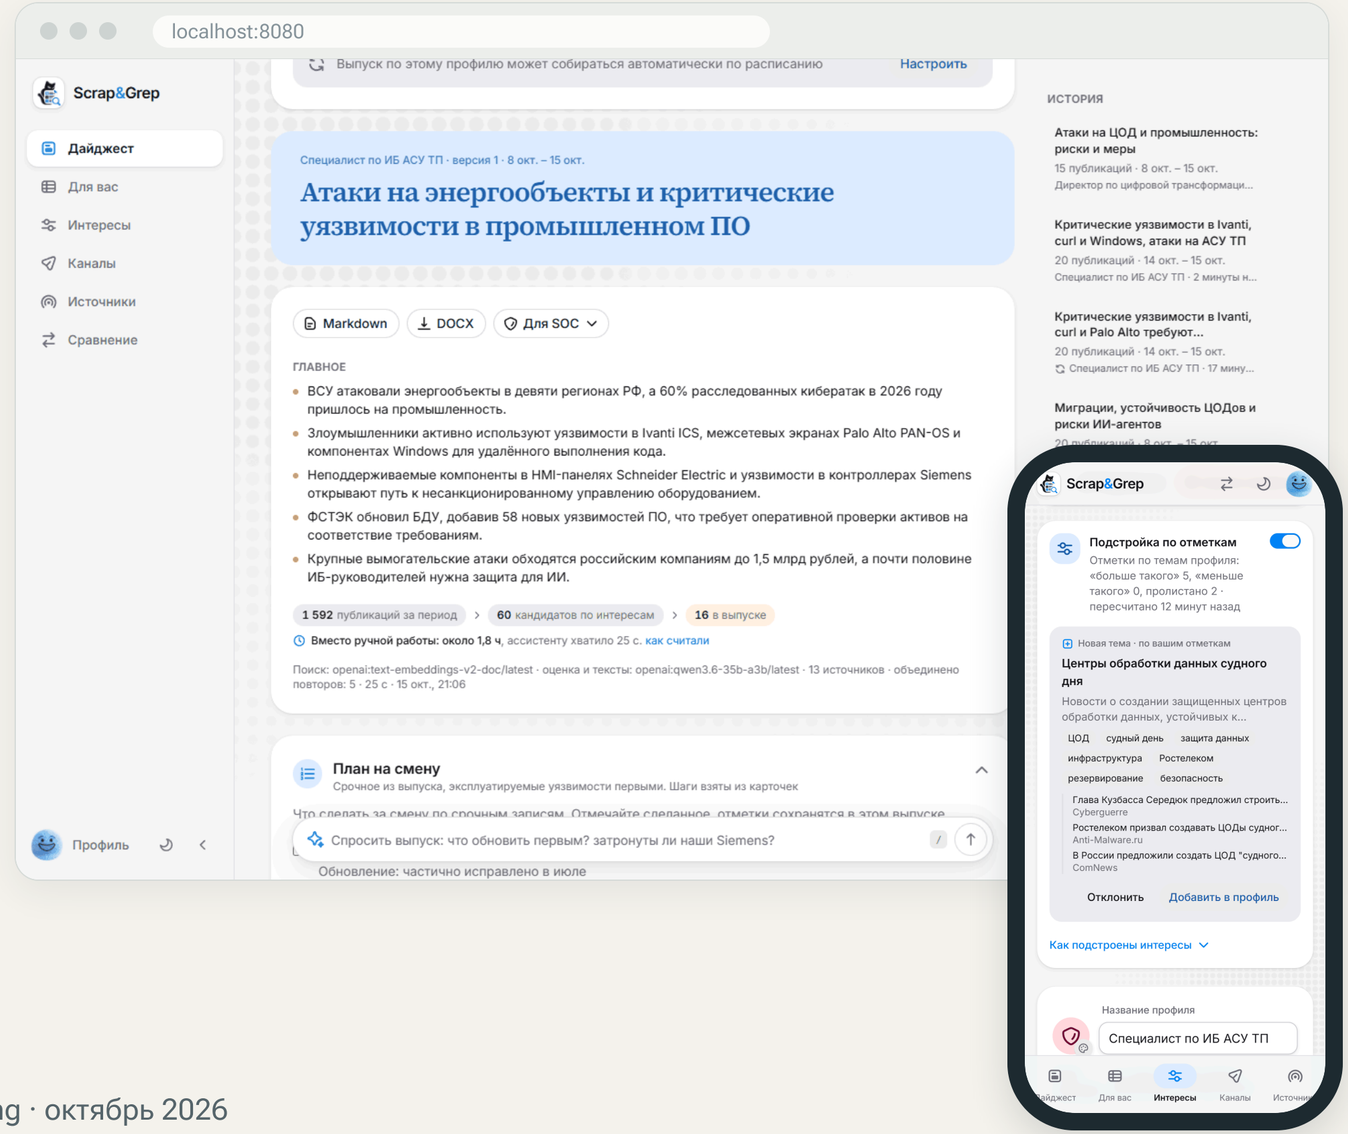
Scrap&Grep

Выпуск новостей ИБ под каждого читателя собирается за 24 секунды

Выпуск специалисту на Qwen3.6 35B в Yandex AI Studio. 104 источника, отбор по интересам, приоритет по правилу датасета организаторов и сверка с CISA KEV и БДУ ФСТЭК. Специалисту подробно за сутки, руководству тезисно за неделю.



Хакатон «ИИ-ассистенты для энергетики», финал · команда misis-mojarung · октябрь 2026

ЗАДАЧА ЗАКАЗЧИКА

Недельный выпуск вручную занимает у аналитика 102,5 минуты, четырём читателям это 34 999 ₽ в месяц

Только в списках организаторов **62** источника: 24 сайта и 18 Telegram-каналов для специалистов, 20 сайтов для руководства.

Часть сайтов не пускает бота: Cloudflare, Akamai, страницы, которые собирает скрипт.

Специалисту нужны детали каждый день, руководству выводы раз в неделю.

Аналитик ИБ собрал два выпуска одной недели за 205 минут и успел просмотреть около 80 публикаций из 1 737.



Ручная сборка в месяц при недельном выпуске каждому читателю: 102,5 минуты на выпуск по журналу аналитика, час аналитика SOC стоит 1 179 ₽.

Медиана аналитика SOC 149 000 ₽, Хабр Карьера, 10.08.2026; взносы 30%; 1 972 рабочих часа в 2026 году. Журнал аналитика: docs/eval/vs-analyst.md. Расчёт: docs/BUSINESS.md, «Экономика».

РЕШЕНИЕ

Scrap&Grep делает каждый шаг работы аналитика сам и показывает, почему

1

Сбор

104 источника, из 62 позиций списков организаторов читаются 60. Защищённые сайты читаются лестницей способов, свой адрес добавляет любой читатель.

2

Отбор

Профиль читателя: интересы, исключения, порог. Модель оценивает 60 кандидатов, у каждой записи и каждого отказа есть причина.

3

Приоритет

Правило датасета: атака на энергетику и промышленность РФ выше остальных, уязвимость с эксплойтом выше. Эксплойт сверяется с CISA KEV и БДУ ФСТЭК.

4

Выпуск

Специалисту за сутки с планом на смену, руководству за неделю с выводами и брифингом голосом. Markdown и DOCX, из браузера, консоли или на почту.

Аналитик ИБ собрал те же два выпуска за ту же неделю вручную: сравнение на следующем слайде.

Аналитик собрал те же два выпуска вручную за 205 минут, ассистент за 85 секунд

Время на два выпуска



Время аналитика - его журнал: 75 минут на просмотр источников и по 65 минут на каждый выпуск. Ассистент собрал оба выпуска в 144 раза быстрее и просмотрел все публикации недели.

	Ассистент	Аналитик
Выпуск специалисту	70,5 с	102,5 мин
Выпуск руководству	14,7 с	102,5 мин
Записей в выпусках	19 и 15	14 и 9
Просмотрено публикаций	все: 1 737 и 1 757	около 80

Оба выпуска специалисту ставят в «Главное» 0-day в Citrix NetScaler с высоким приоритетом. Аналитик добавил регуляторику и удары по энергосистеме, ассистент - бюллетени CISA ICS по оборудованию АСУ ТП, 17 уязвимостей SCADA «Каскад» и сверку номеров по CISA KEV и БДУ.

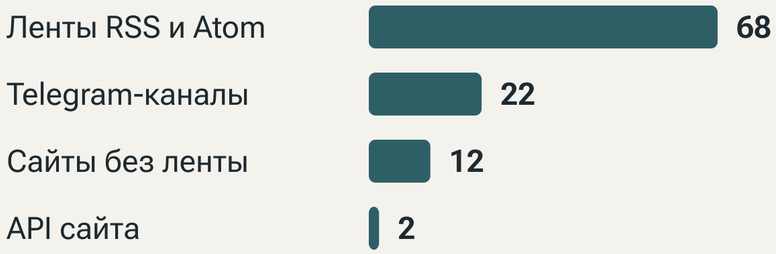
4 октября в каталог вошли ещё 19 источников, среди них Help Net Security, на который ссылается аналитик.

Неделя 25 сентября - 2 октября 2026 года, 69 источников. docs/eval/vs-analyst.md; ответ аналитика целиком - examples/vs-analyst.

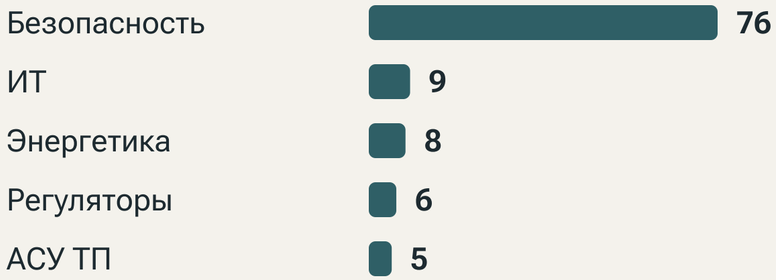
КРИТЕРИЙ 1 · РЕПРЕЗЕНТАТИВНОСТЬ МАТЕРИАЛОВ

Каталог из 104 источников читает 60 из 62 позиций списков организаторов

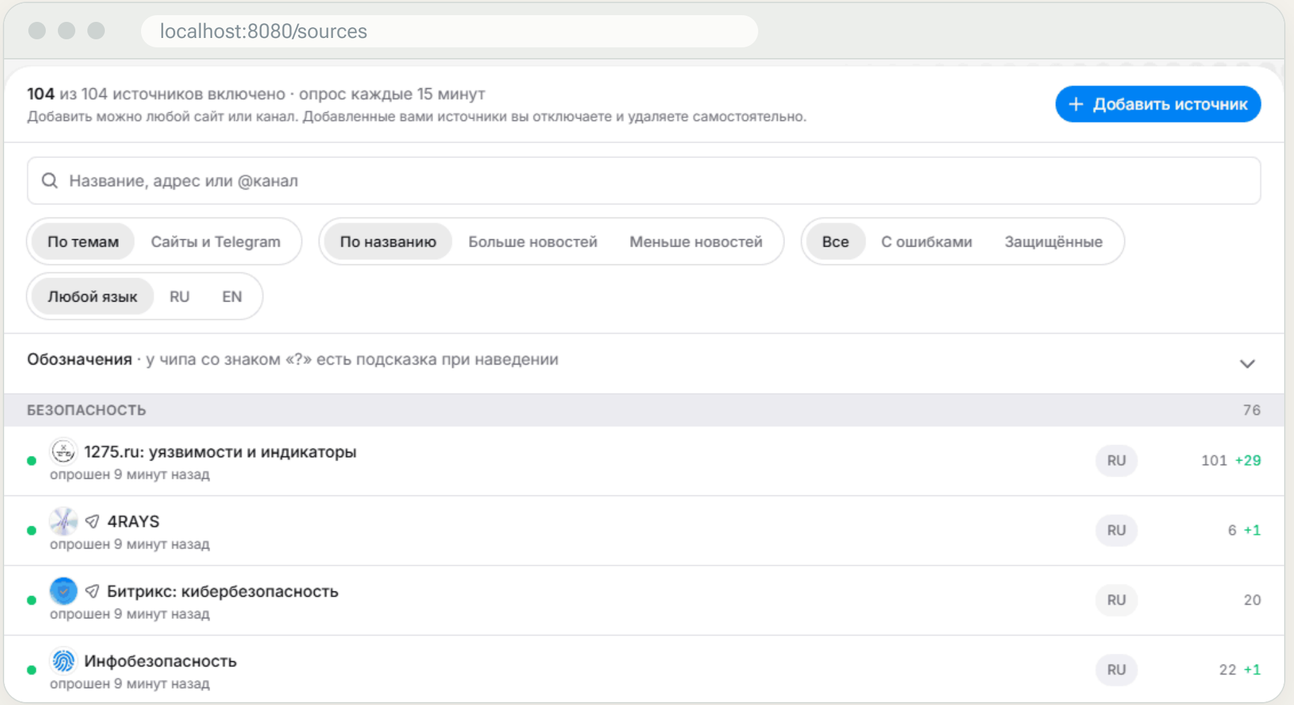
104 источника по виду



по теме



docs/DECISIONS.md, «Источники из датасета»; README, «Быстрый запуск».



1 737 публикаций за неделю сравнения с аналитиком. Стек приходит со снимком из **2 068** реальных публикаций 75 источников и собирает выпуск руководству сразу после старта.

Каждый источник опрашивается раз в 15 минут, сайт без ленты читается как страница новостей. Любой читатель добавляет сайт или канал по адресу, ассистент сам понимает, что это.

КРИТЕРИЙ 1 · РЕПРЕЗЕНТАТИВНОСТЬ МАТЕРИАЛОВ

На 21 примере организаторов прочитаны все страницы, тип записи совпал в 7 случаях из 7

Каждый пример прошёл те же шаги, что запись выпуска, и лежит рядом с желаемым выводом.

Что сравнивали	Результат	Пояснение
Страницы примеров	21 из 21	каждая страница читается так же, как источник каталога
Специалисты: тип и приоритет	тип 7 из 7, приоритет 4 из 7	у specialist-4 в датасете стоит CVE другой уязвимости, WSUS из specialist-7
Специалисты: посты Telegram	тип по содержанию	датасет кладёт пост в «Инфо» по источнику, Scrap&Grep даёт посту об уязвимости карточку и ссылки из поста, как в желаемом выводе
Руководство: двенадцать признаков датасета	23 из 36 у gpt-oss:120b	у Qwen3.6 35B в Yandex AI Studio 24 из 36, у Alice AI LLM 22

Ещё в репозитории восемь выпусков в Markdown и DOCX, собранные 15 октября на текущем коде, и три сценария смены интересов с причиной у каждой статьи, которая пришла или ушла.

Прогон 15 октября 2026 года: examples/models/README.md, «Датасет организаторов»; examples/dataset/README.md; examples/README.md.

КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

Стек поднимается одной командой: один образ бэкенда в шести ролях и граф сборки с чекпоинтами

СБОР

worker-ingest
RSS, t.me/s, страницы, лестница чтения, эмбеддинги новых статей

FlareSolverr
для сайтов, которые проверяют посетителя скриптом

ХРАНЕНИЕ

PostgreSQL 18
статьи, pgvector и полнотекстовый поиск, чекпоинты графа

Valkey
очереди задач, кеш ответов модели, прогресс

ClickHouse
события показов и отметок

СБОРКА И МОДЕЛЬ

worker-digest
граф LangGraph, оценка и выжимки веером

Языковая модель
Qwen3.6 35B-A3B в Ollama или vLLM либо Yandex AI Studio

worker-profile, worker-media
резюме и вкус читателя; ролики и брифинг

ДОСТУП

web (Caddy) и api (FastAPI)
интерфейс, REST, прогресс по SSE, MCP

cli
выпуск в Markdown и DOCX одной командой

scheduler
опрос раз в 15 минут, выпуски по расписанию

Граф сборки выпуска

prepare профиль и период › **retrieve** поиск по смыслу и словам › **grade** веер: задача на кандидата › **select** порог, лимит, исключения › **cluster** склейка повторов, темы › **summarize** веер: задача на статью › **compose** разделы, «Главное» › **persist** запись выпуска

Упавший воркер продолжает с прерванного шага: чекпоинты в PostgreSQL. docs/ARCHITECTURE.md, «Компоненты» и «Граф сборки».

КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

Сайт, который не пускает бота, читается следующей ступенью лестницы

1

Обычный запрос

SecurityLab, Habr: **0,2-0,7 с**

2

Заголовки браузера

для сайтов, которым хватает User-Agent браузера

3

Отпечаток Chrome

Cloudflare с 403 и заглушкой: Dark Reading **0,9 с**, Cybernews **1,0 с**, SecurityWeek **1,4 с**, Netskope **4,2 с**

4

FlareSolverr в стеке

проверка Cloudflare с JS: **15,9 с**; McAfee за Akamai

Прокси

Общий, свой у источника или пулом с ротацией при 403 и 429.

Видно у источника

Ступень и причина записываются: «403, заглушка Cloudflare на шаге «обычный запрос», прочитан через curl_cffi».

Безопасно

Защита от SSRF на каждой ступени: внутренние адреса не читаются.

Замеры 2 октября 2026 года, без прокси. docs/DECISIONS.md, «Сбор: лестница способов чтения».

КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

Запись сверяется с текстом статьи, с базами уязвимостей и с тем, вышло ли исправление

Сбор — полный текст со страницы, если в ленте анонс

› **Поиск** — по смыслу и по словам для каждого интереса

› **Оценка** — 60 кандидатов по шкале 0-3 с причиной

› **Склейка** — одна уязвимость - одна запись

› **Запись** — тип, карточка, приоритет, «почему важно»

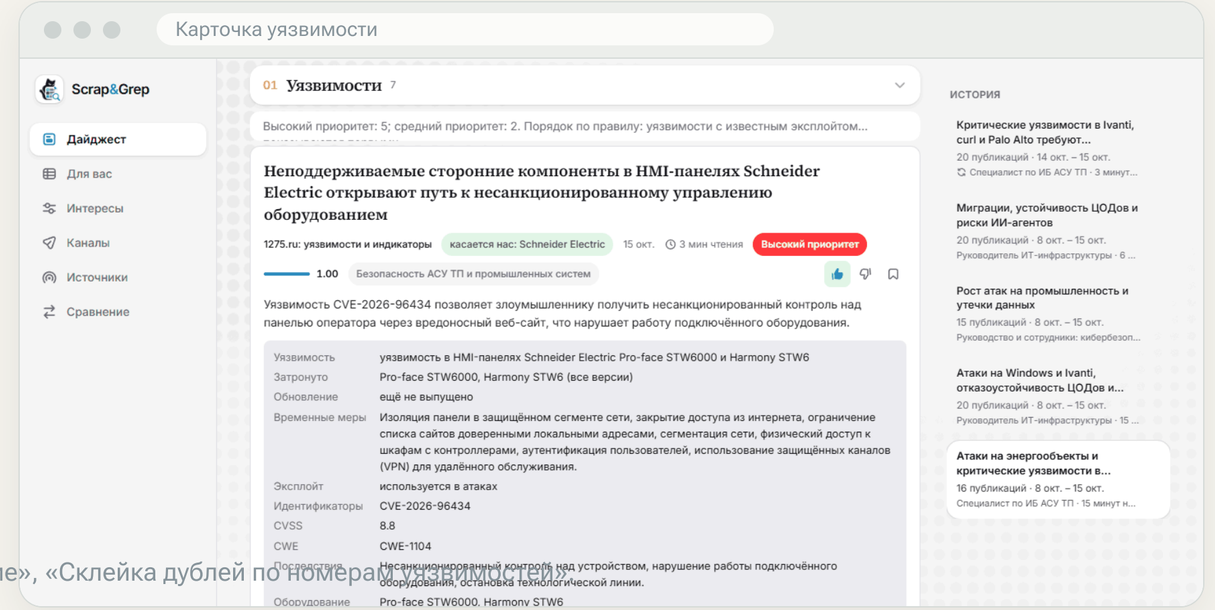
› **Проверка** — чего нет в статье, нет в карточке; номера по CISA KEV и БДУ

› **Выпуск** — Markdown с оглавлением, DOCX, история

Модель сама вызывает `lookup_vulnerability`: CISA KEV, БДУ ФСТЭК, NVD, EPSS и Exploit-DB по локальным копиям. Номера, о которых она не спросила, граф проверяет сам.

Пока производитель только обещает обновление, карточка так и пишет, а «почему важно» и план на смену советуют временные меры. «Что изменилось» сообщает об исправлении, когда оно вышло.

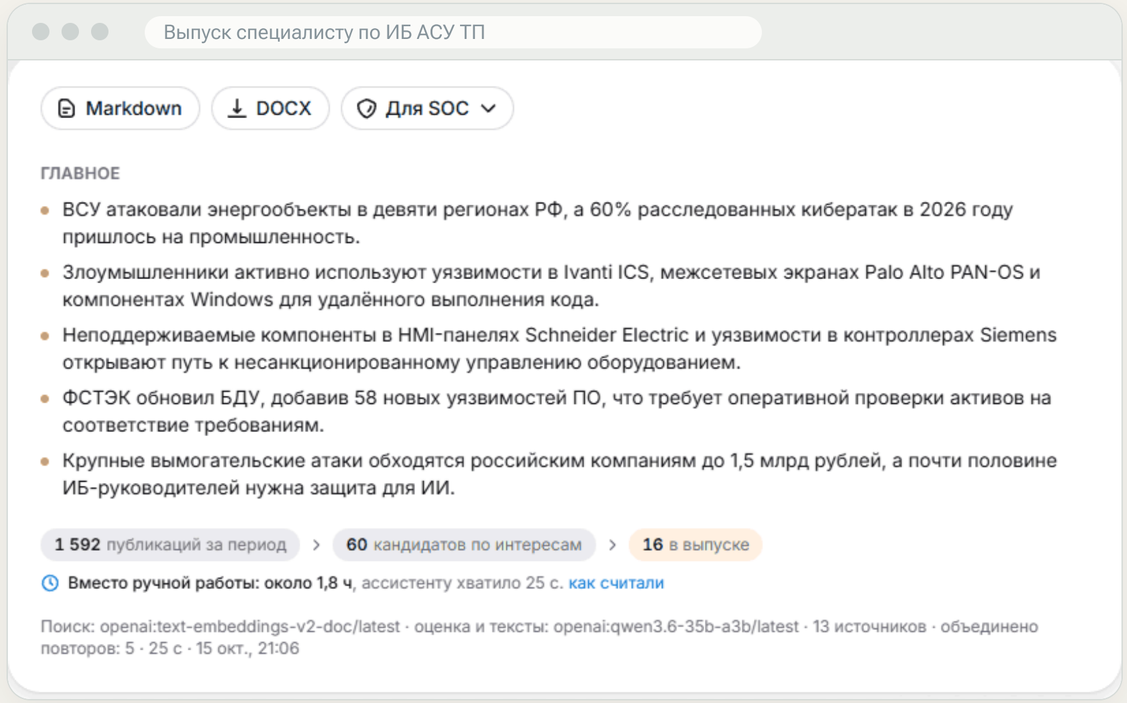
Пересказы одной уязвимости склеиваются по номерам CVE и БДУ: в восьми выпусках примеров склеен 51 пересказ.



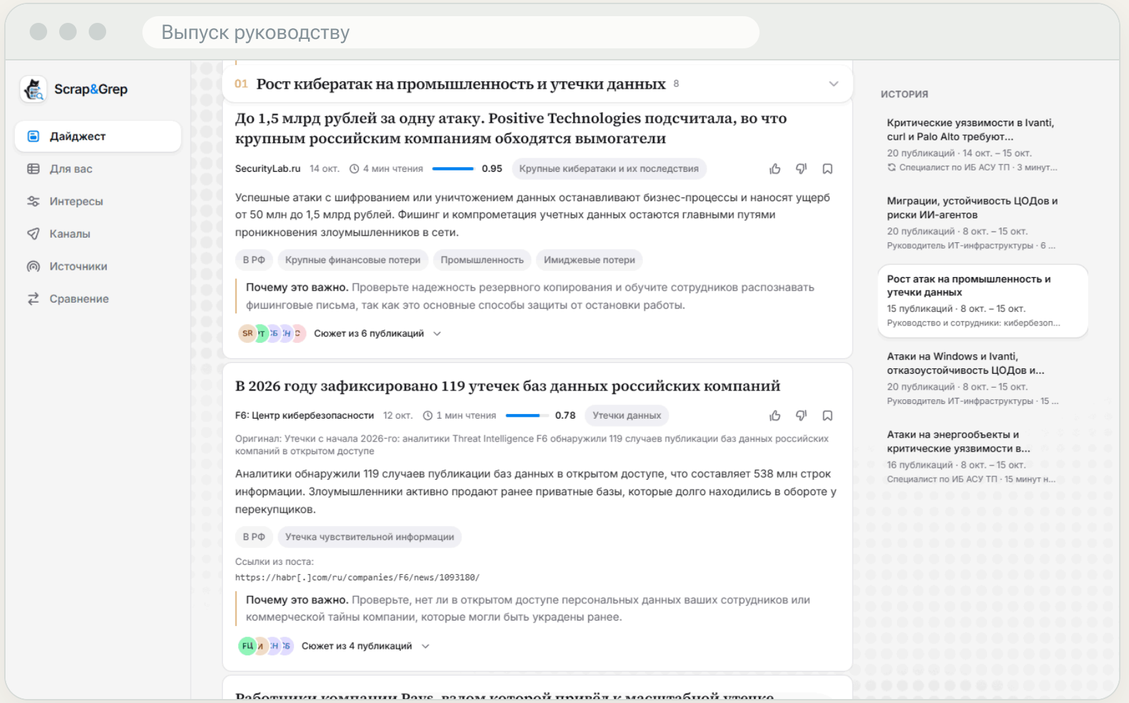
docs/DECISIONS.md, «Инструмент модели», «Совет согласован с тем, вышло ли исправление», «Склейка дублей по номерам уязвимостей»

КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

Специалист получает выпуск за сутки с планом на смену, руководство выводы за неделю



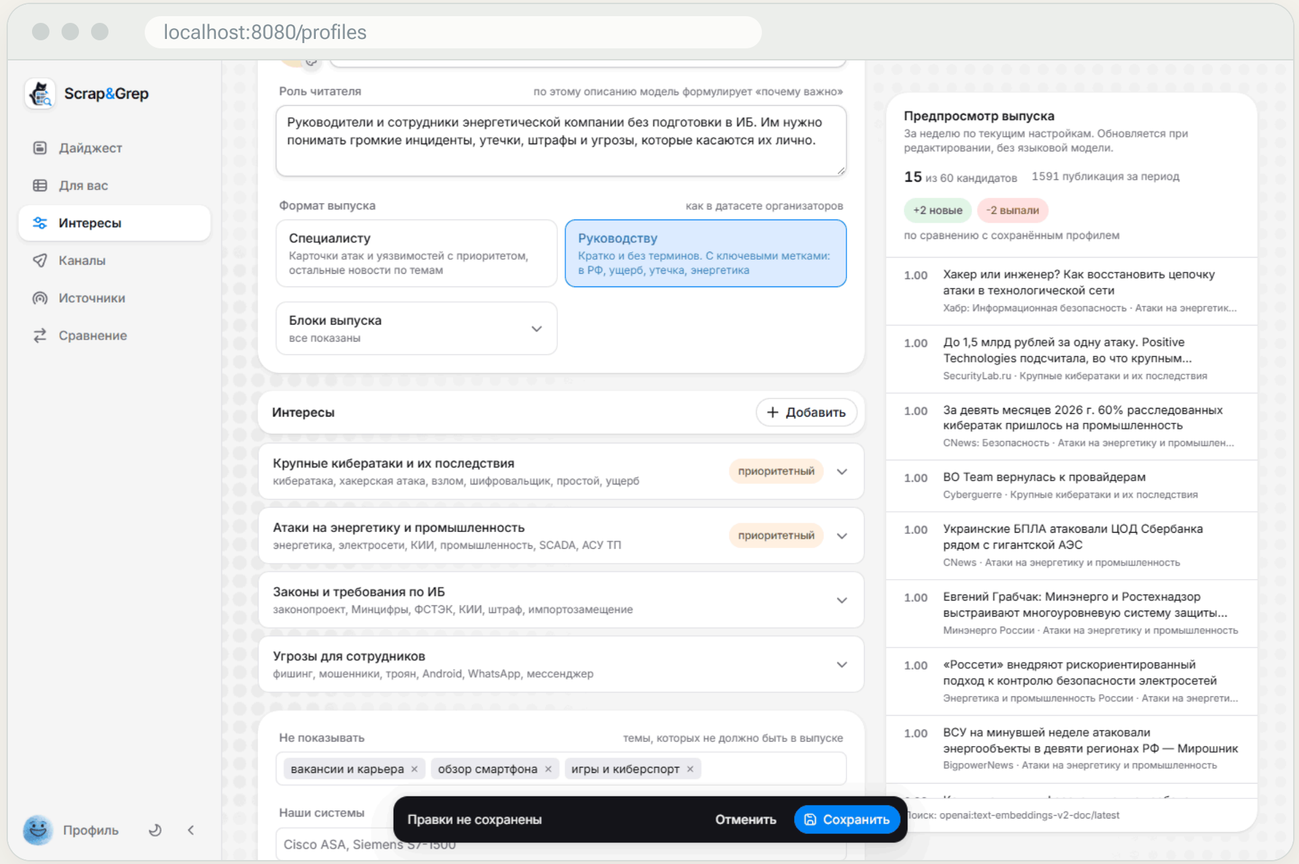
«Главное», путь от публикаций периода до записей и строка «Вместо ручной работы». Дальше план на смену с галочками, которые хранятся на сервере, и пометка «касается нас» у продуктов из «Наших систем».



Записи в одно-два предложения с признаками датасета, без номеров уязвимостей. Наверху «Что это значит для нас», рядом период в цифрах против прошлого выпуска и брифинг голосом на две минуты.

КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

Правка профиля сразу меняет подборку, и это видно ещё до сборки



Убран интерес «Уязвимости»

19 записей → 20: пришло 7, ушло 6.

Исключение «уязвимости Citrix»

Пришло 5, ушло 4; запись о Citrix ушла с причиной.

Порог 0,50 → 0,70, размер 20 → 10

Ушли 9 записей, у каждой её оценка.

Поля карточек и блоки выпуска

Профиль прячет лишние строки карточек и любые из 14 блоков вокруг записей.

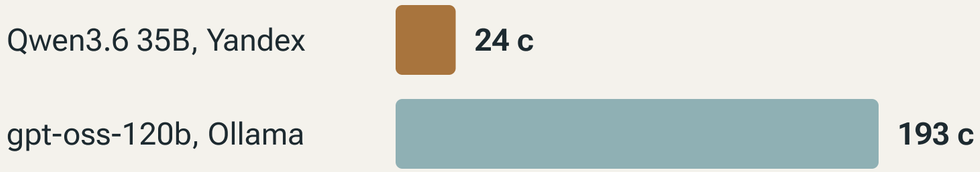
Предпросмотр работает без языковой модели. examples/change; examples/README.md; docs/TASK-MAP.md, «Что нового в финале».

КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

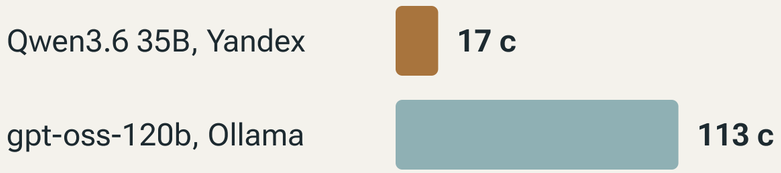
Весь стек переходит на Yandex AI Studio переменными в .env, код не меняется

Сборка на одном сценарии, секунды

Выпуск специалисту



Выпуск руководству



Сквозная проверка на полном стеке Yandex: выпуск за 21,6 с, ролик на 55 с с голосом SpeechKit за 175 с.

Замер	Yandex	Сравнение
Признаков руководства из 36	24	23 у gpt-oss-120b
Точность первых 20 кандидатов	0,65	0,40 у embeddinggemma
Полнота первых 60 кандидатов	0,443	0,426 у embeddinggemma

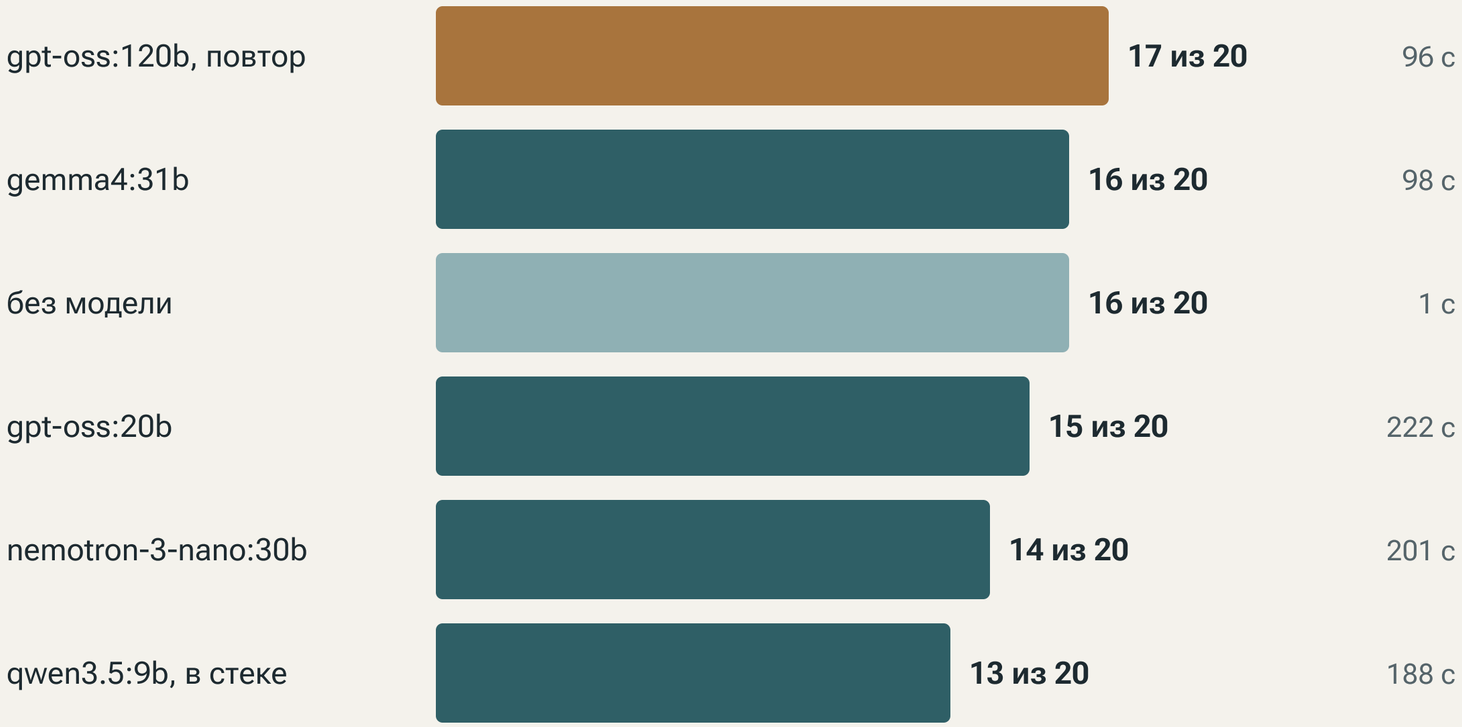
Тексты пишет Qwen3.6 35B или Alice AI LLM через OpenAI-совместимый API, эмбеддинги считает text-embeddings-v2, ролики и брифинги озвучивает SpeechKit. Видеокарта не нужна.

Профиль «Специалист по ИБ АСУ ТП». README, «Модели Яндекса»; docs/INSTALL.md, «Модели Яндекса»; docs/eval/retrieval.md; docs/DECISIONS.md, «Yandex AI Studio».

КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

Сценарий выпуска держится на любой модели и без модели

Записей, совпавших с первым прогоном gpt-oss:120b, из 20, и время сборки



Разделы, карточки, приоритеты и проверка работают на всех моделях: выпуск собирается целиком.

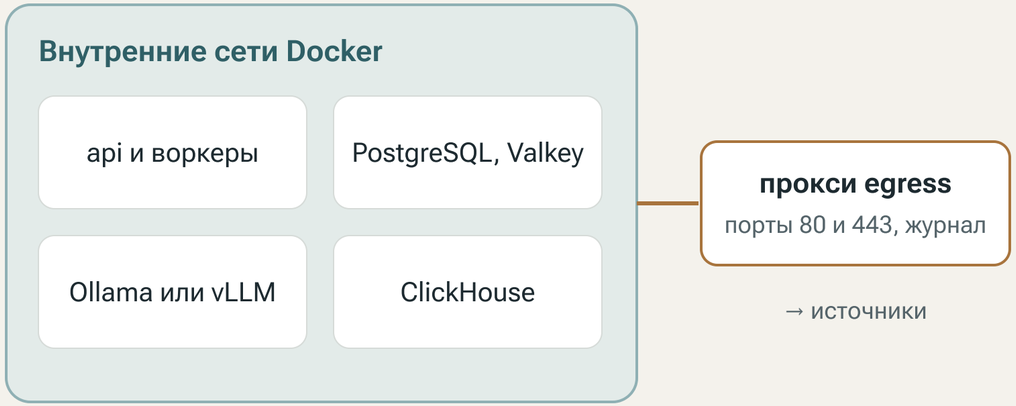
Отбор держится на поиске: даже без модели 16 записей из 20 те же. Два прогона одной gpt-oss:120b совпадают в 17.

Модель меняется в .env. Примеры собраны на gpt-oss:120b, в стеке по умолчанию пишет локальная Qwen3.6 35B-A3B.

Выпуск специалисту по ИБ АСУ ТП за неделю примеров: 60 кандидатов, до 20 записей, пустой кеш, 15 октября 2026 года. examples/models/README.md

КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

Стек работает в закрытом контуре, наружу ходит только загрузчик источников



`offline_bundle.sh save`: 7 образов ядра 4,7 ГБ и модели 1,6 ГБ за 4 мин 21 с. `load` в пустой каталог за 3 мин 29 с, копия поднялась без сети и прошла `scripts/smoke.py` целиком.

Модель финала на своём сервере: аренда и окупаемость

Модель и карта	В месяц	С предоплатой	Окупается с читателей
Qwen3.6 35B-A3B, 22,6 ГБ; RTX 4090 24 ГБ	69 674 ₽	52 256 ₽	9
gpt-oss-120b, 65 ГБ; H100 80 ГБ	246 074 ₽	221 467 ₽	29

Стек ассистента ставится на тот же сервер. По опубликованным замерам скорости gpt-oss-120b собирает выпуск специалисту примерно за 45 с на H100 и за 70 с на A100, это около 80 и 50 выпусков в час. Цена с предоплатой указана за 30 дней вперёд, окупаемость посчитана по читателям с недельными выпусками.

docs/INSTALL.md, «Закрытый контур» и «Требования к железу»; docs/eval/economics.md, immers.cloud, 14.10.2026; docs/QUALITY.md, «Что проверено».

КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

966 тестов бэкенда и 841 тест фронтенда, одни и те же проверки в GitLab и GitHub Actions

966

тестов бэкенда на настоящих PostgreSQL, Valkey и ClickHouse, покрытие строк 86%

841

тест фронтенда в 115 файлах, Testing Library и MSW, покрытие строк 98%

17 и 15

заданий GitLab CI и GitHub Actions из одних скриптов `ci/`; прогон GitHub Actions 15 октября прошёл целиком

28

выпусков примеров проверяет `check_examples.py`: у каждой уязвимости одна запись

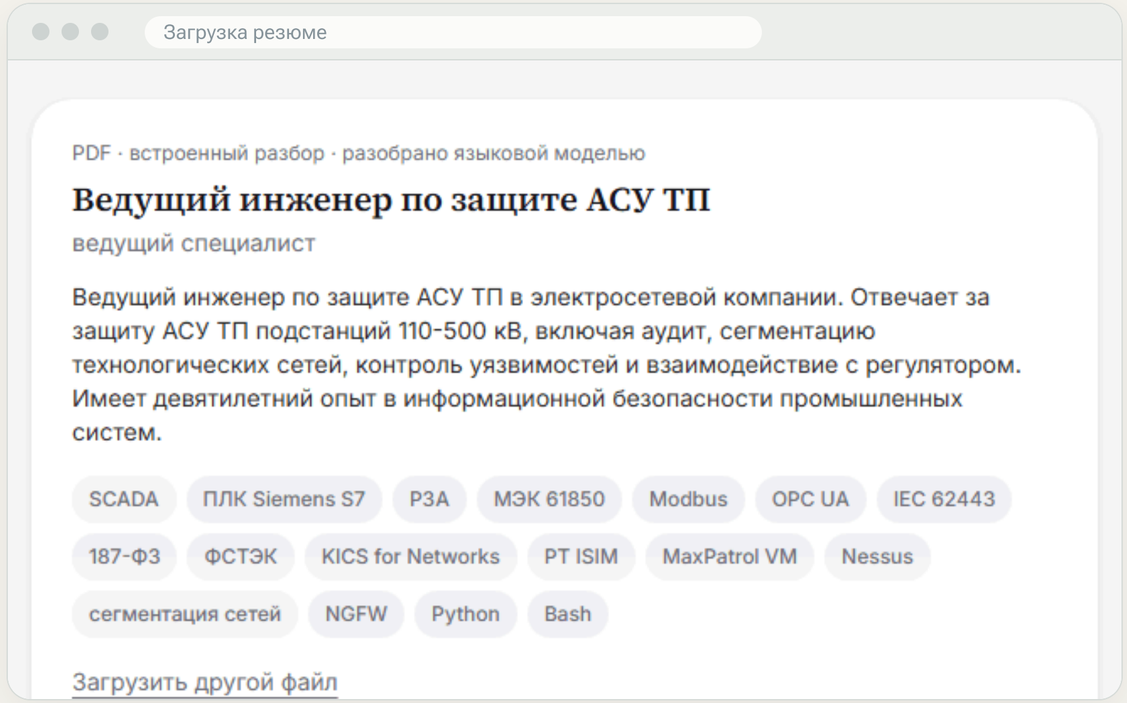
На запущенном стеке

Проверка	Результат
Нагрузка на чтение, k6, 50 пользователей	4 реплики api: 615 запр/с, p95 128 мс
Остановка одной из четырёх реплик api	0 неудачных из 15 670 запросов
Остановка Ollama посреди сборки	выпуск готов через 2 с, недостающее дописал автономный алгоритм
`scripts/smoke.py`, 15 октября	прошёл каждый шаг пути жюри

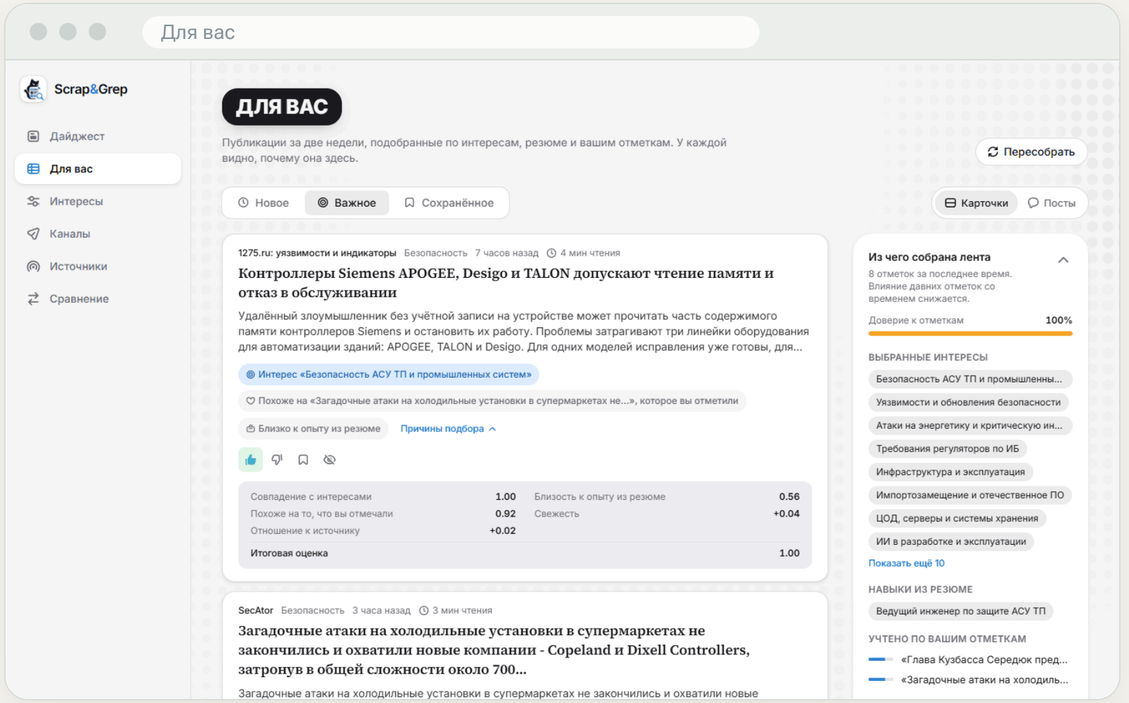
ruff и mypy --strict, oxlint и tsc без замечаний. docs/QUALITY.md, «Тесты» и «Что проверено»; docs/CI.md.

КРИТЕРИЙ 2 · ПЕРСОНАЛИЗАЦИЯ

Резюме задаёт профиль с первой минуты, и лента сразу подбирается под специалиста



Должность, навыки и предложенные темы. Имя и контакты вырезаются до анализа, файл удаляется сразу после разбора; сканы читает docling.



У каждой статьи видно, почему она здесь: интерес, опыт из резюме, похожее на то, что читатель отметил; «Причины подбора» раскладывают оценку на части.

КРИТЕРИЙ 2 · РЕКОМЕНДАТЕЛЬНАЯ СИСТЕМА

Своя рекомендательная модель строит ленту по вкусу читателя и учится на его отметках

1. Кандидаты
один SQL-запрос: близость статей за две недели к каждой грани вкуса по эмбеддингам pgvector и ключевым словам

2. Оценка
грани с доверием: интерес 0,45, резюме 0,10, выученная по лайкам до 0,35, избегаемая вычитается; плюс свежесть, источник, «нравится коллегам»

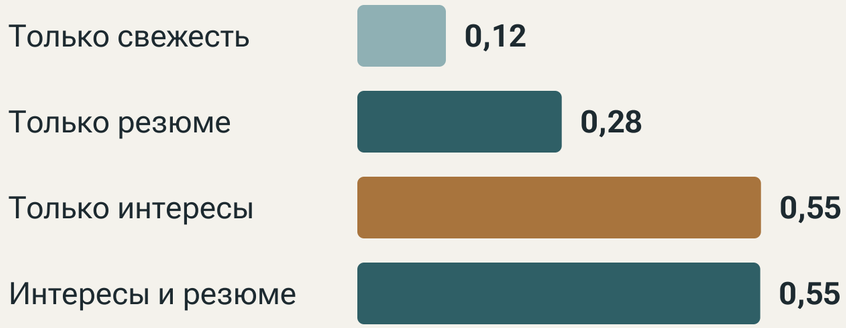
3. Перестановка
копии одной истории выбрасываются, серии одного источника разбиваются, каждое седьмое место - «Что-то новое»

4. Обучение
ночью LightGBM LambdaRank на показах и отметках из ClickHouse с поправкой на место в списке

Каждая карточка объясняет оценку: какой интерес совпал, что из резюме, на что похоже из отмеченного. Отметки весят по-разному (сохранение 1,2, лайк 1,0, открытие 0,4, скрытие -0,7, дизлайк -1,0) и слабеют вдвое за три недели.

LightGBM заменяет ручные веса, только если на трёх последних днях поднимает nDCG@20 больше чем на 0,01; половина читателей остаётся контрольной группой. Так в выдачу попадает только модель, которая доказала прирост на отметках читателей.

nDCG@20 ленты специалиста по ИБ АСУ ТП до первых отметок

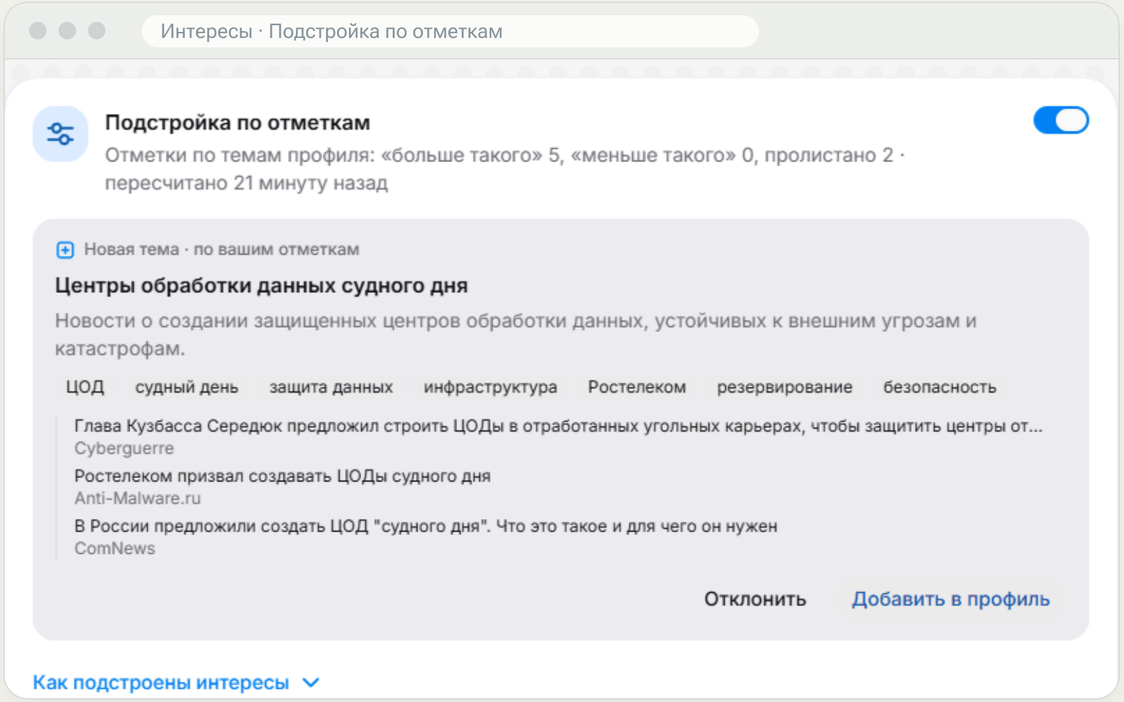


Интересы дают главный прирост, резюме помогает, пока интересов нет. Неделя из 871 статьи.

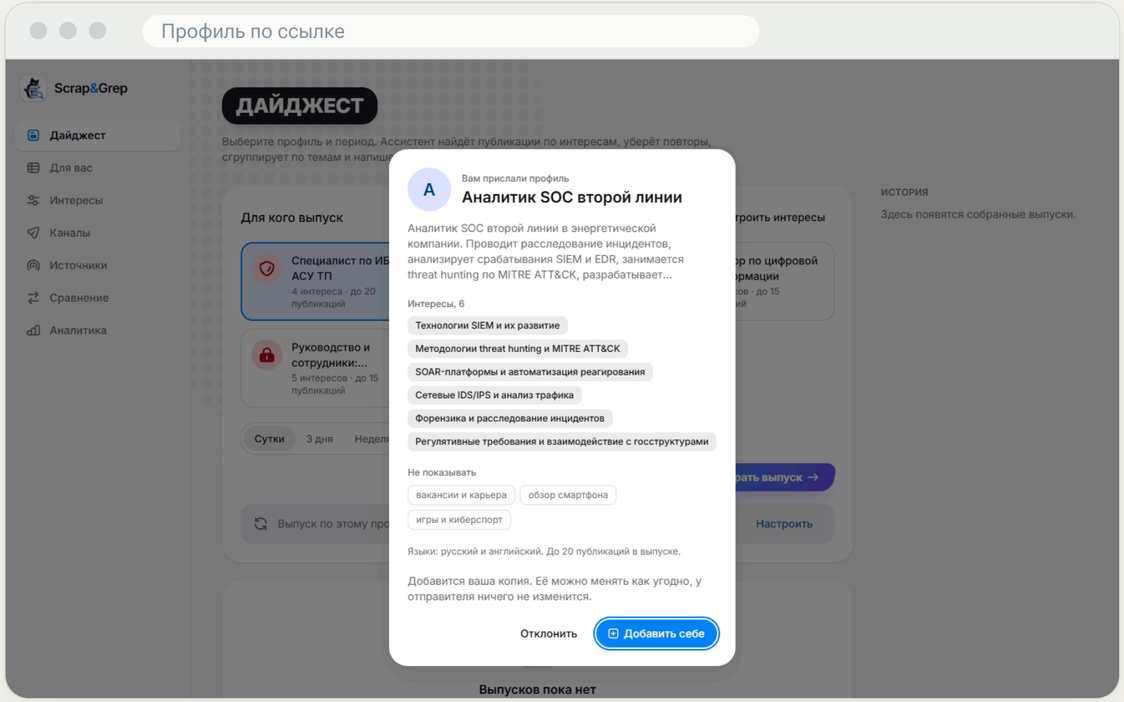
docs/ARCHITECTURE.md, «Персональная лента»; docs/DECISIONS.md, «Обучаемое ранжирование»; docs/eval/recsys.md, docs/eval/ranker.md.

КРИТЕРИЙ 2 · ПЕРСОНАЛИЗАЦИЯ

Профиль учится на отметках читателя и передаётся коллеге по ссылке



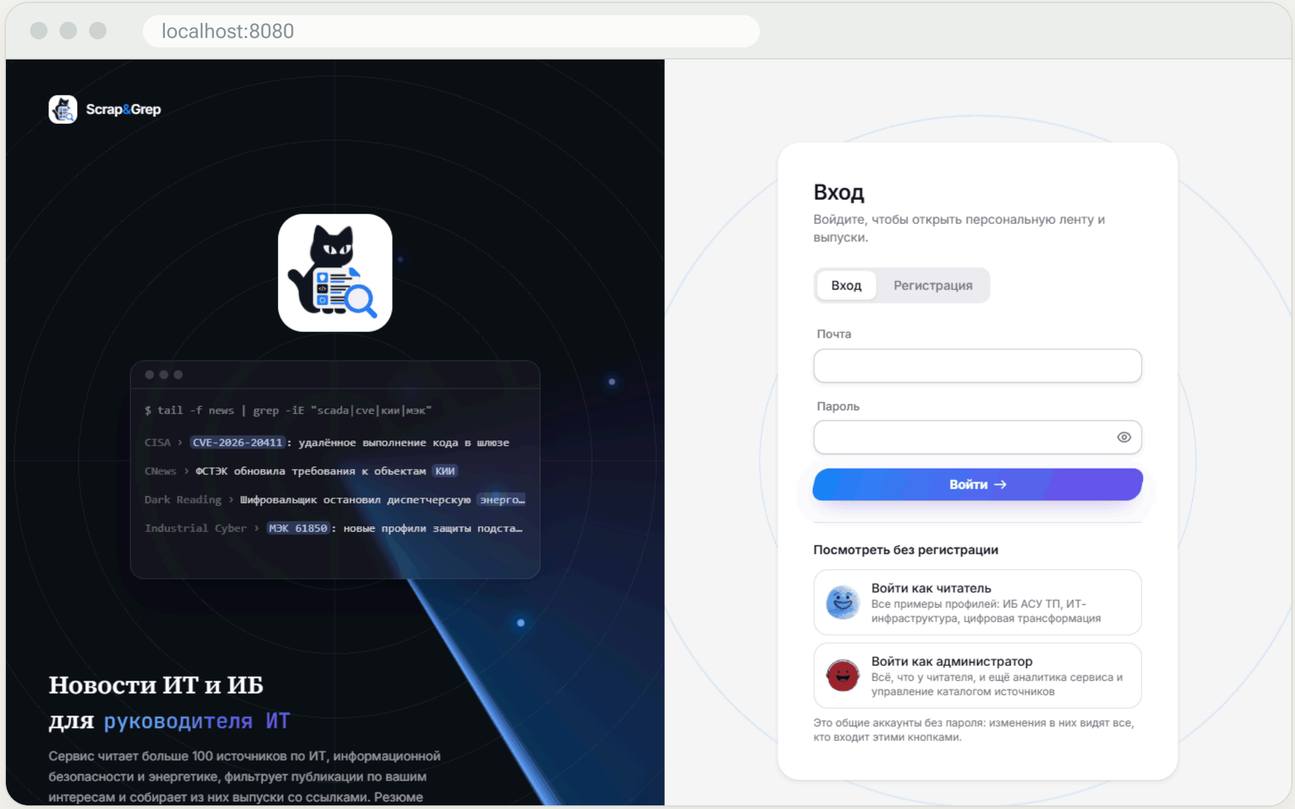
Вес интереса растёт от «больше такого» и падает от «меньше такого», не больше чем на десятую часть; новая тема предлагается по статьям, которые профиль сам не нашёл. Сохранённый профиль при этом не меняется.



Коллега открывает ссылку и добавляет копию профиля себе. Выпуски, отметки и резюме владельца по ссылке не видны.

КРИТЕРИЙ 2 · ПЕРСОНАЛИЗАЦИЯ

Читатель входит одной кнопкой, проходит тур по разделам и читает статьи по-русски



Общие аккаунты

«Войти как читатель» открывает четыре примера профилей без пароля, «Войти как администратор» добавляет «Аналитику» и инструменты каталога.

Знакомство

Десять шагов по всем разделам с мини-превью, затем первый профиль интересов по резюме, из шаблона или вручную и первый выпуск.

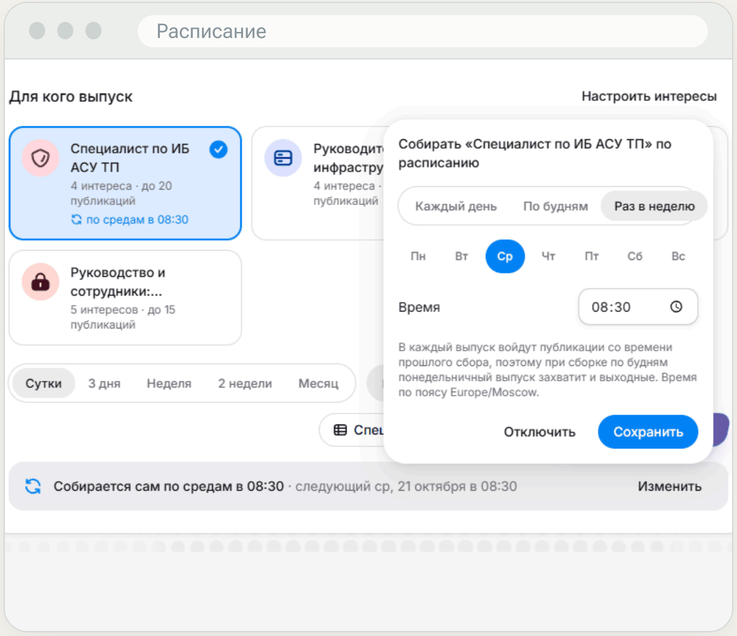
Перевод в читалке

Английские и китайские статьи модель переводит на русский. Код, номера CVE и БДУ и числа не меняются, оригинал открывается одной кнопкой.

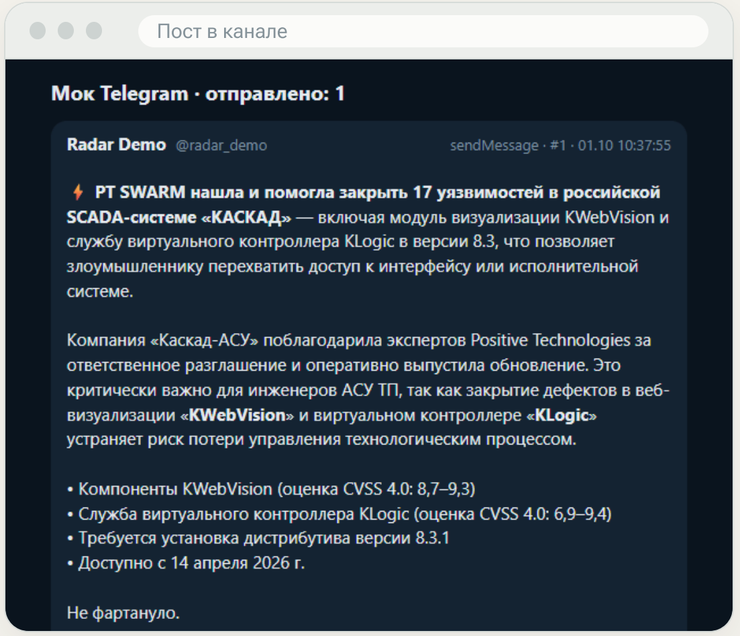
docs/TASK-MAP.md, «Что нового в финале»; docs/DECISIONS.md, «Перевод английских и китайских статей».

КРИТЕРИЙ 3 · БИЗНЕС-ОРИЕНТИРОВАННОСТЬ

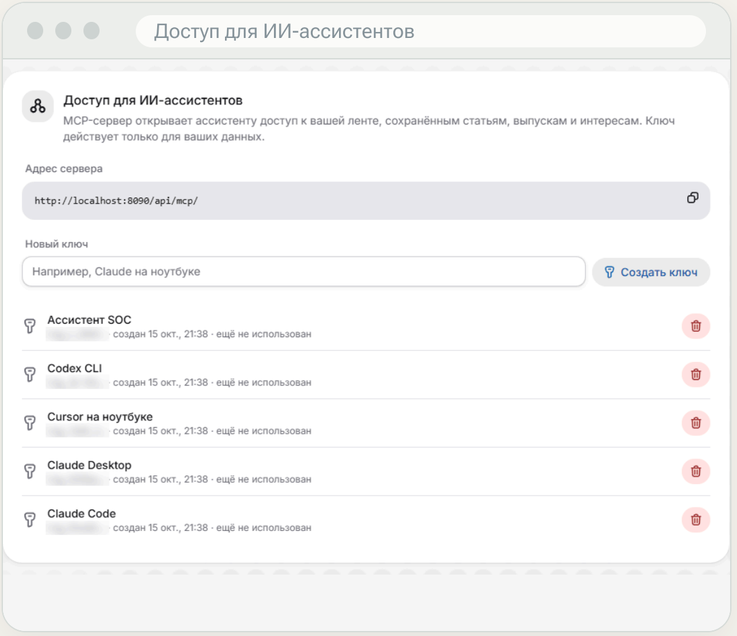
Выпуск приходит по расписанию, в Telegram-канал компании и ИИ-ассистенту сотрудника



Каждый день, по будням или раз в неделю, в местное время читателя. Кнопка «На почту» шлёт выпуск письмом с DOCX во вложении.

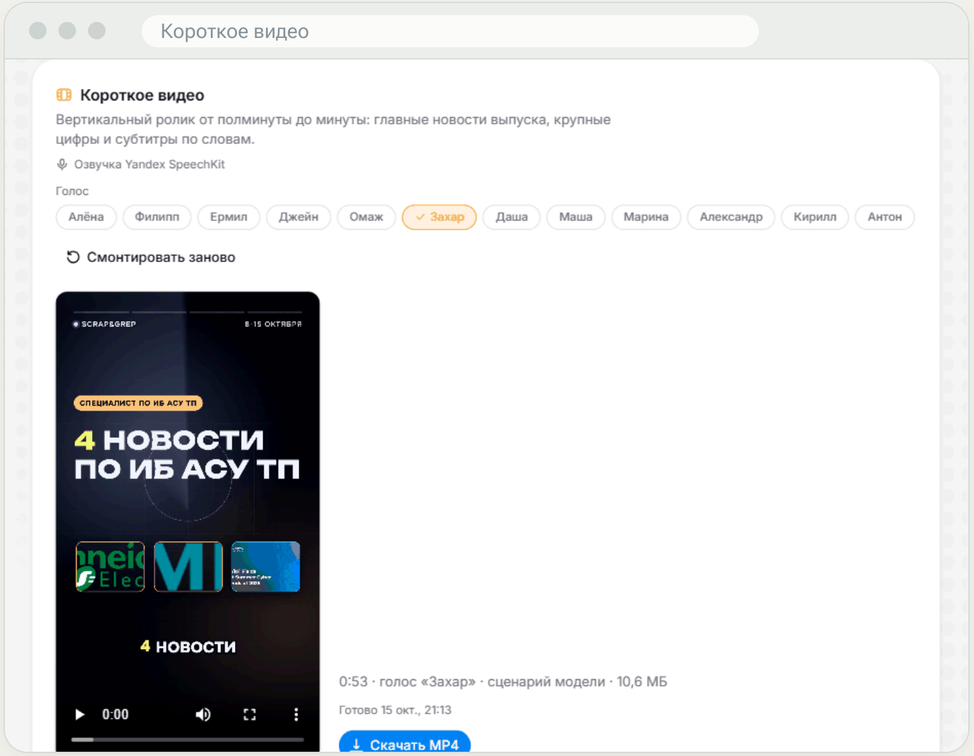


Боты публикуют новости по расписанию: у каждого канала своя аудитория, тон и подача ссылок, черновик уходит на проверку.

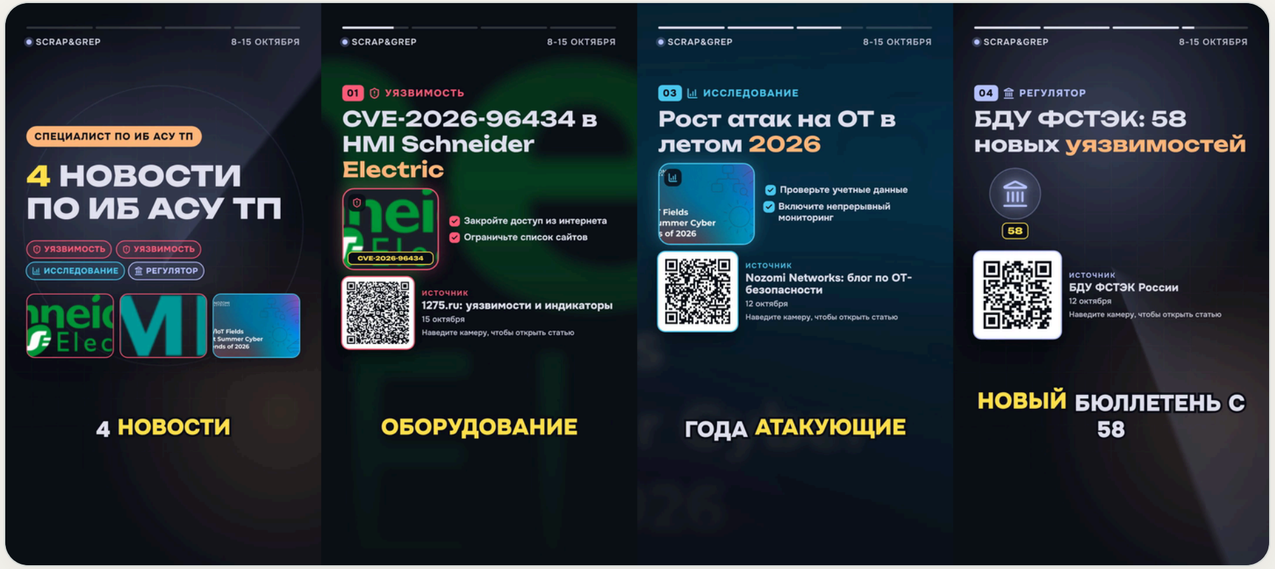


MCP-сервер отдаёт Claude, Cursor и другим клиентам ленту, сохранённое, выпуски и интересы только этого читателя. Ключ показывается один раз.

Ролик по выпуску и брифинг для руководства озвучивает Yandex SpeechKit без видеокарты



Двенадцать голосов SpeechKit или четыре голоса Qwen3-TTS в стеке, страница называет движок и голос.



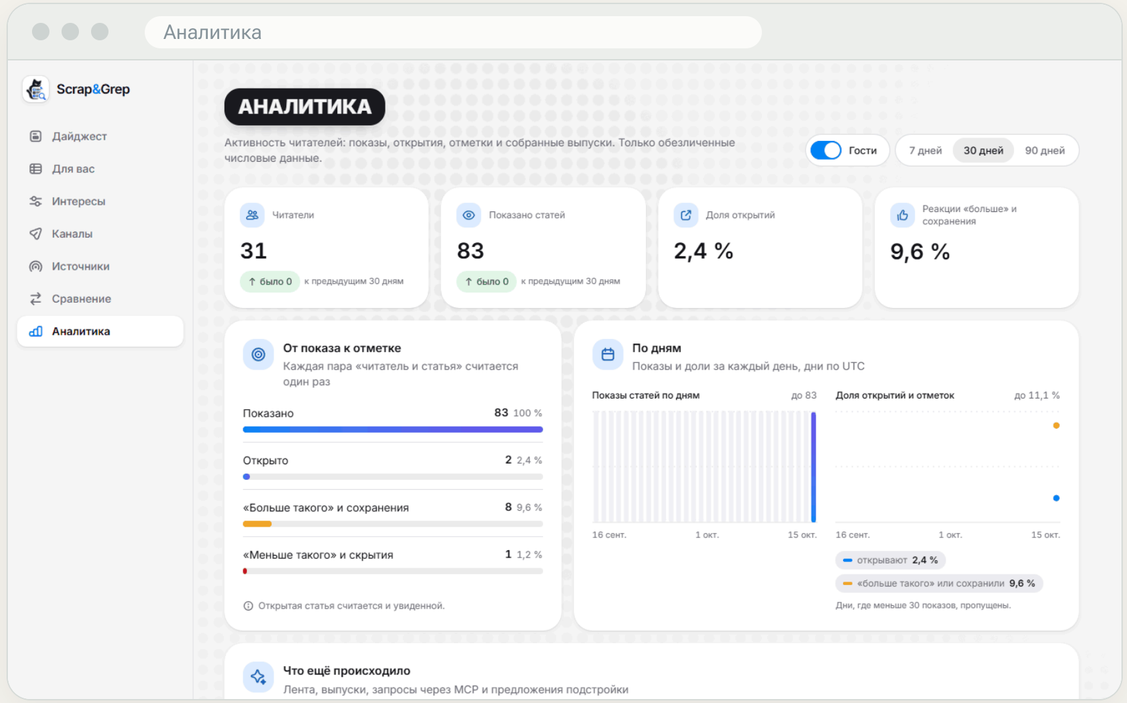
Вертикальный ролик на полминуты-минуту: картинки статей, крупная цифра новости, QR-код статьи и субтитры по словам. Цифры сценария сверяются с текстом новости.

«Слушать брифинг» пересказывает выпуск руководству голосом за две минуты, без номеров уязвимостей и адресов.

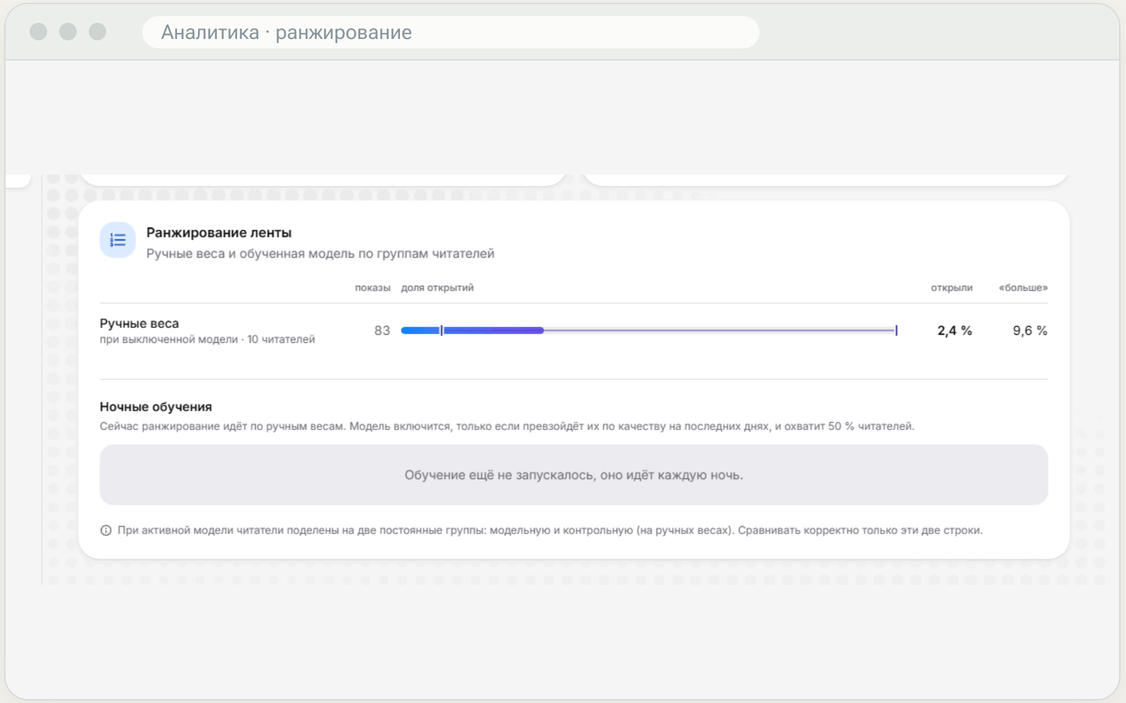
docs/ARCHITECTURE.md, «Короткие видео» и «Брифинг голосом»; docs/INSTALL.md, «Модели Яндекса».

КРИТЕРИЙ 3 · БИЗНЕС-ОРИЕНТИРОВАННОСТЬ

Аналитика показывает, что сотрудники видят, открывают и отмечают



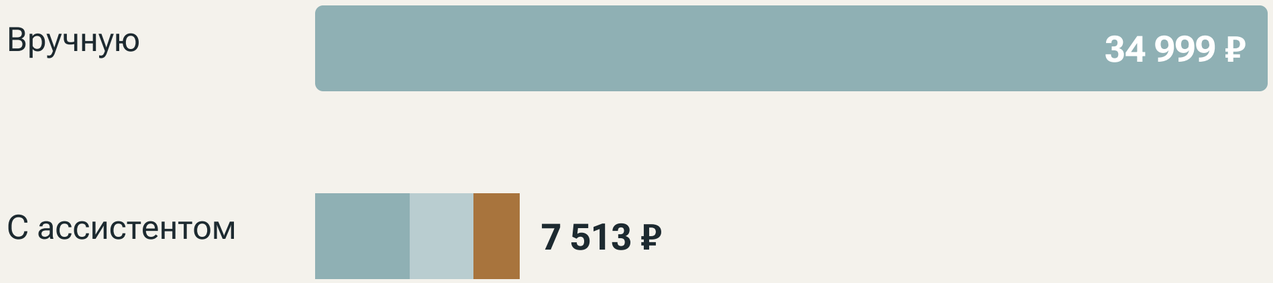
Читатели, доли открытий и отметок, путь от показа к отметке и дни. Только числа, без текстов и адресов; раздел видит администратор.



Ручные веса и обученная модель по группам читателей, ночные обучения. Те же события - метрики пилота: открытия и отметки по неделям.

КРИТЕРИЙ 3 · БИЗНЕС-ОРИЕНТИРОВАННОСТЬ

Четырём читателям с недельными выпусками ассистент экономит 27 486 ₽ в месяц



сервер под стек: 4 ядра, 8 ГБ	3 476 ₽
сопровождение, 2 часа администратора	2 357 ₽
тариф облачной модели, $20	1 679 ₽

Ручная сборка: 102,5 минуты на выпуск, 8 750 ₽ в месяц на читателя

27 486 ₽

экономии в месяц на трёх специалистов и руководство, **329 832 ₽** в год

Ассистент окупается, пока ручной выпуск дольше 22 минут. У аналитика он занял 102,5 минуты, в 4,7 раза дольше.

Выпуск специалисту: 171 753 токена на вход и 17 338 на выход, 3,04 ₽. Руководству 1,96 ₽.

Хабр Карьера, 10.08.2026; тарифы Ollama; курс ЦБ 83,9497 ₽ на 15.10.2026; Selectel. Проверено 14.10.2026. docs/BUSINESS.md, «Экономика».

ВНЕДРЕНИЕ

Пилот на 4 недели проверит главное число: полноту выпуска против аналитика

Установка

Закрытый контур: образы, веса модели, корпоративный прокси, проверочный сценарий. 10-20 сотрудников из разных групп, у каждого свой профиль.

Что измеряем

Время ручной сборки и проверки, полнота «обязательных» по разметке человека, nDCG@20, доля открытых записей и отметок. Шкала, файлы и скрипт разметки готовы.

Успех

Полнота «обязательных» не ниже 90% и проверка недельного выпуска не дольше 30 минут.

Попробовать

```
docker compose up -d --build
```

Откройте localhost:8080 и нажмите «Войти как читатель».

```
docker compose run --rm cli digest
```

Оба выпуска в Markdown и DOCX в папке out/.

Репозиторий: git.codenrock.com/codenrock/ii-assistenty/misis-mojarung/assistent-dlya-sozdaniya-it-ib-daydzhestov

docs/BUSINESS.md, «Пилот»; docs/eval/human; README, «Быстрый запуск».