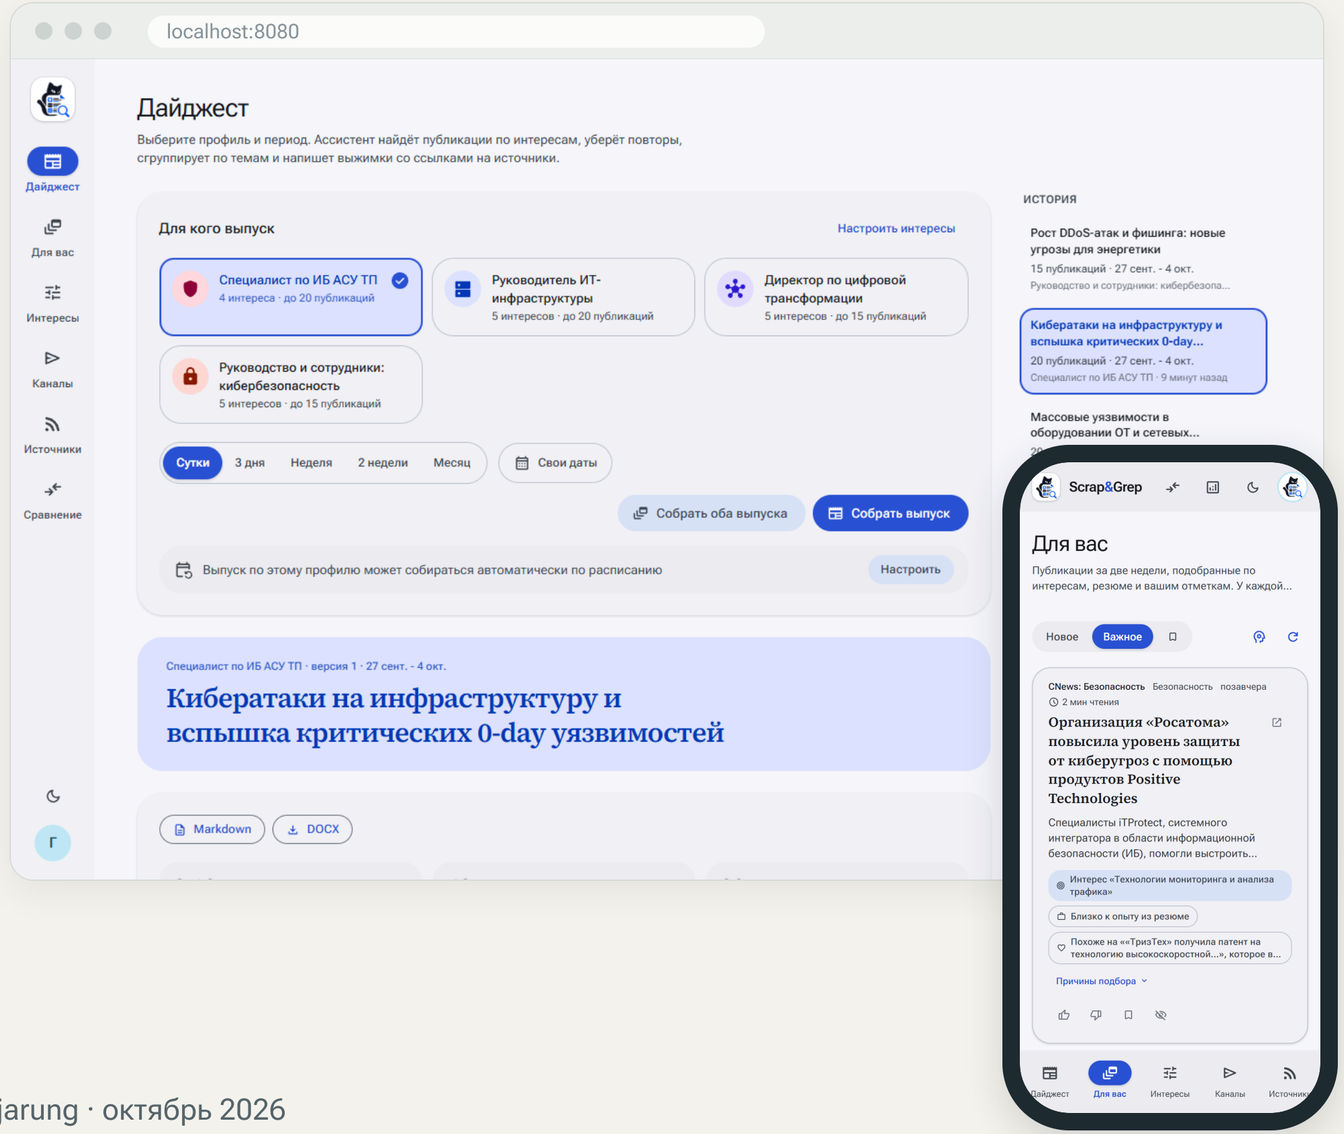
Scrap&Grep

Выпуск новостей ИБ под каждого читателя собирается за одну-четыре минуты

Сбор из 107 источников, отбор по интересам, приоритет по правилу заказчика и проверка фактов по CISA KEV и БДУ ФСТЭК. Специалисту каждый день, руководству раз в неделю.



Хакатон «ИИ-ассистенты для энергетики», полуфинал · команда misis-mojarung · октябрь 2026

ЗАДАЧА ЗАКАЗЧИКА

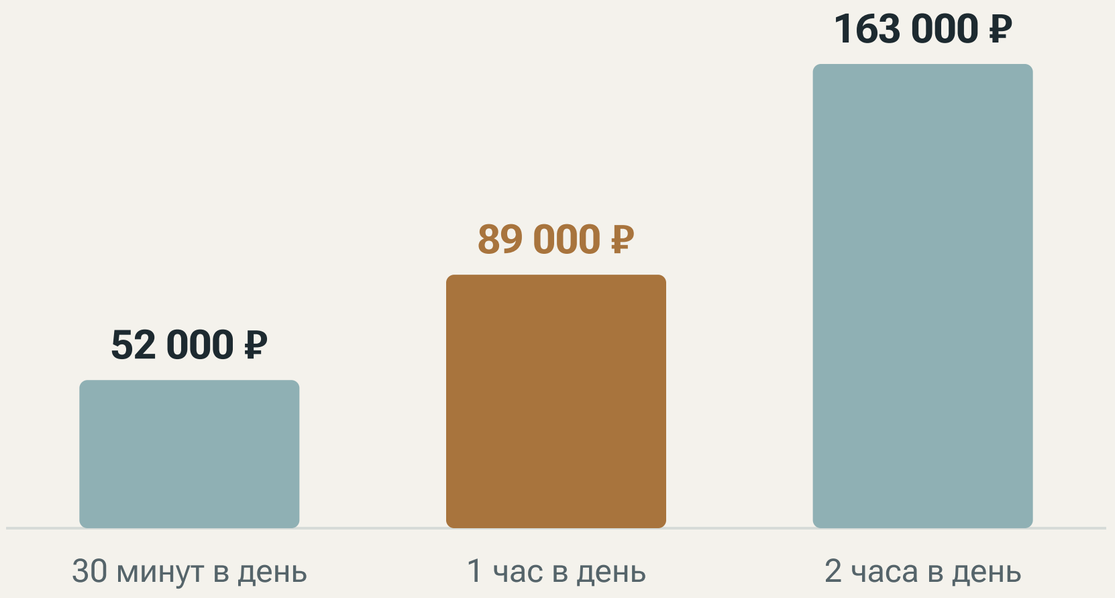
Ручной мониторинг новостей ИБ стоит команде из трёх специалистов около 89 000 ₽ в месяц

Только в списках организаторов **62** источника: 24 сайта и 18 Telegram-каналов для специалистов, 20 сайтов для руководства.

Часть сайтов не пускает бота: Cloudflare, Akamai, страницы, которые собирает скрипт.

Специалисту нужны детали каждый день, руководству выводы раз в неделю.

Полнота и приоритет зависят от того, кто читает на этой неделе: единого правила нет.



Стоимость в месяц при разном времени на мониторинг у каждого из трёх специалистов, плюс 3 часа в неделю на сводку руководству. Часы в день - допущение, пока их не замерили у аналитика.

Медиана SOC-аналитика 149 000 ₽, Хабр Карьера, I полугодие 2026; с взносами 1 170 ₽ за час. Расчёт: docs/BUSINESS.md, «Экономика».

РЕШЕНИЕ

Scrap&Grep делает каждый шаг работы аналитика сам и показывает, почему

1

Сбор

107 источников, из списков организаторов все 62. Защищённые сайты читаются лестницей способов, любой адрес добавляется из интерфейса.

2

Отбор

Профиль читателя: интересы, исключения, порог. Модель оценивает 60 кандидатов, у каждой записи и каждого отказа есть причина.

3

Приоритет

Правило заказчика: атака на энергетику и промышленность РФ выше остальных, уязвимость с эксплойтом выше. Эксплойт сверяется с CISA KEV и БДУ ФСТЭК.

4

Выпуск

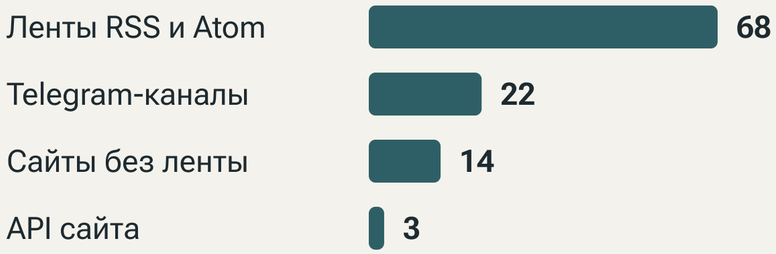
Специалисту за сутки с планом на смену, руководству за неделю с выводами и брифингом голосом. Markdown и DOCX, из браузера или консоли.

Чего пока нет: сравнения с живым аналитиком на одной неделе. Задание, разметка и скрипт метрик готовы (docs/eval/human), разметки человеком ещё нет, поэтому цифр сравнения не приводим.

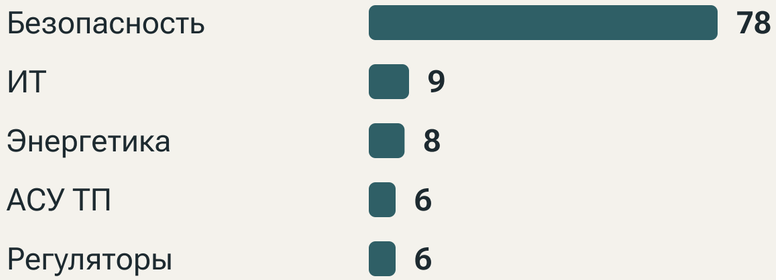
КРИТЕРИЙ 1 · РЕПРЕЗЕНТАТИВНОСТЬ МАТЕРИАЛОВ

Каталог покрывает все 62 источника из списков организаторов и ещё 45 сверх них

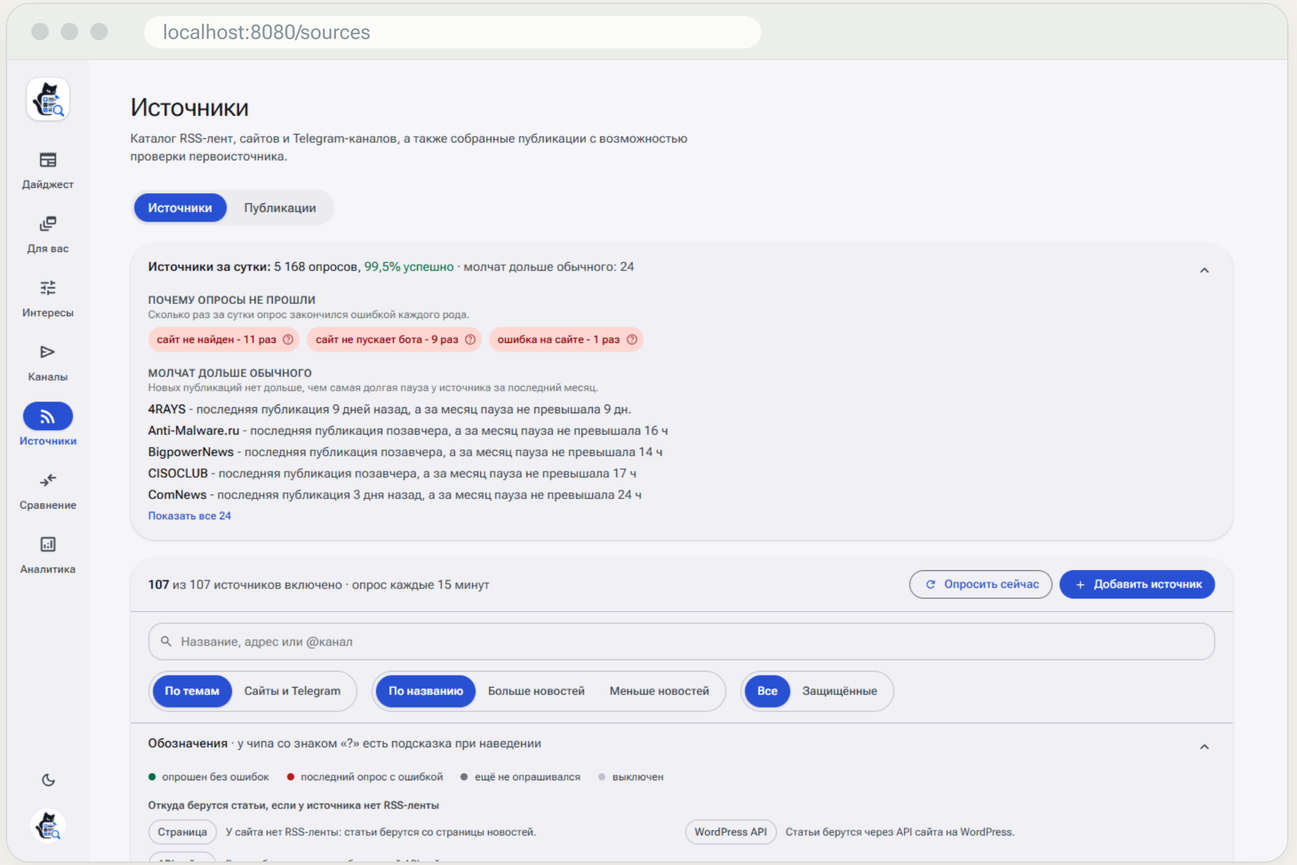
107 источников по виду



по теме



1 737 публикаций за неделю 25.09-02.10. Стек приходит со снимком из **2 109** реальных публикаций и работает без интернета.



Каждый источник опрашивается раз в 15 минут; здоровье за сутки и способ чтения видны в каталоге.

КРИТЕРИЙ 1 · РЕПРЕЗЕНТАТИВНОСТЬ МАТЕРИАЛОВ

На 21 примере организаторов тип записи совпал в 6 случаях из 6, приоритет в 4 из 6

Каждый пример датасета прогнан через те же шаги, что запись выпуска, и положен рядом с желаемым выводом.

Что сравнивали	Результат	Где расходимся и почему
Специалисты: атаки и уязвимости	тип 6 из 6, приоритет 4 из 6	у specialist-4 в датасете чужой CVE (уязвимость WSUS из specialist-7), у specialist-3 страной жертвы названа РФ при атаке на Европу и Азию
Специалисты: посты Telegram	тип по содержанию	датасет кладёт пост в «Инфо» по источнику; Scrap&Grep даёт посту об уязвимости карточку уязвимости и ссылки из поста, как в желаемом выводе
Руководство: двенадцать признаков датасета	22 из 32, лишних 13	по каждому из 11 примеров видно, какой признак совпал, какой пропущен и какой поставлен сверх датасета
Чтение страниц примеров	19 из 21	два сайта ответили HTTP 202 и 401

Ещё в репозитории: выпуски для четырёх профилей в Markdown и DOCX и три сценария смены интересов с разбором, что пришло и что ушло.

examples/dataset/README.md; examples/README.md

КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

Сайт, который не пускает бота, читается следующей ступенью лестницы

1

Обычный запрос

SecurityLab, Habr: **0,2-0,7 с**

2

Заголовки браузера

для сайтов, которым хватает User-Agent браузера; среди защищённых сайтов списка таких не нашлось

3

Отпечаток Chrome

Cloudflare с 403 и заглушкой: Dark Reading **0,9 с**, Cybernews **1,0 с**, SecurityWeek **1,4 с**, Netskope **4,2 с**

4

Браузер в стеке, FlareSolverr

проверка Cloudflare с JS: **15,9 с**; БДУ АСУ ТП, которую собирает скрипт

Прокси

Общий, свой у источника или пулом с ротацией при 403 и 429.

Видно у источника

Ступень и причина записываются: «Шаг «обычный запрос» не сработал (403), сработал «отпечаток Chrome»».

Безопасно

Защита от SSRF на каждой ступени: внутренние адреса не читаются.

Замеры 2 октября 2026 года, без прокси. docs/DECISIONS.md, «Сбор: лестница способов чтения».

КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

Каждая запись сверяется с текстом статьи и с базами уязвимостей

Сбор — полный текст со страницы, если в ленте анонс

›

Поиск — по смыслу и по словам для каждого интереса

›

Оценка — 60 кандидатов по шкале 0-3 с причиной

›

Склейка — пересказы одной новости становятся одной записью

›

Запись — тип, карточка, приоритет, «почему важно»

›

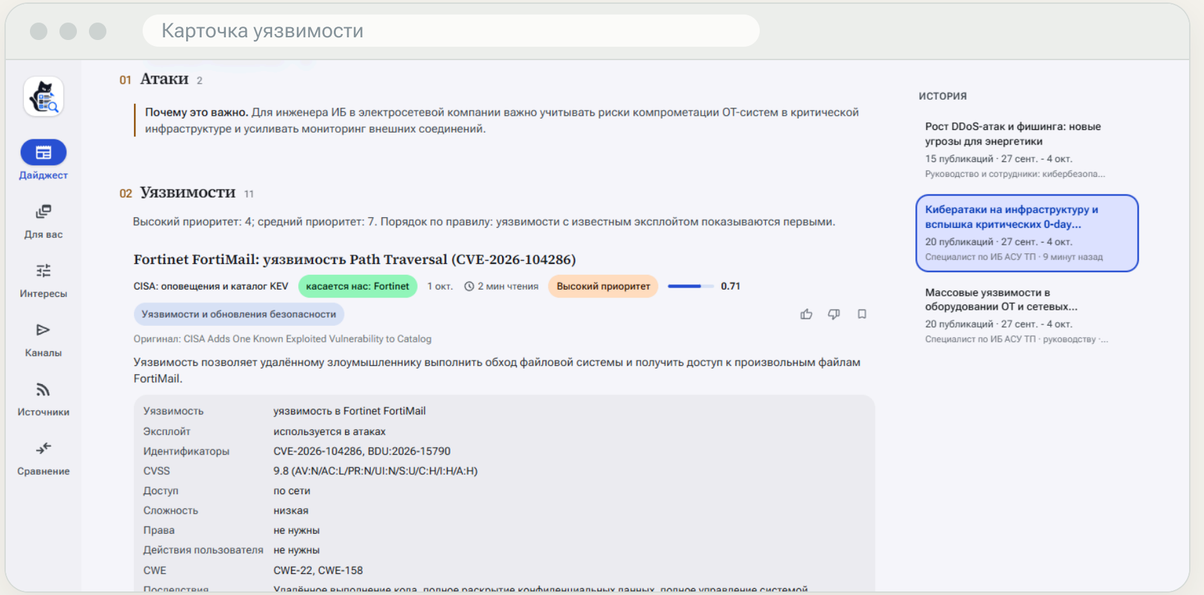
Проверка — чего нет в статье, нет в карточке; номера по CISA KEV и БДУ

›

Выпуск — Markdown с оглавлением, DOCX, история

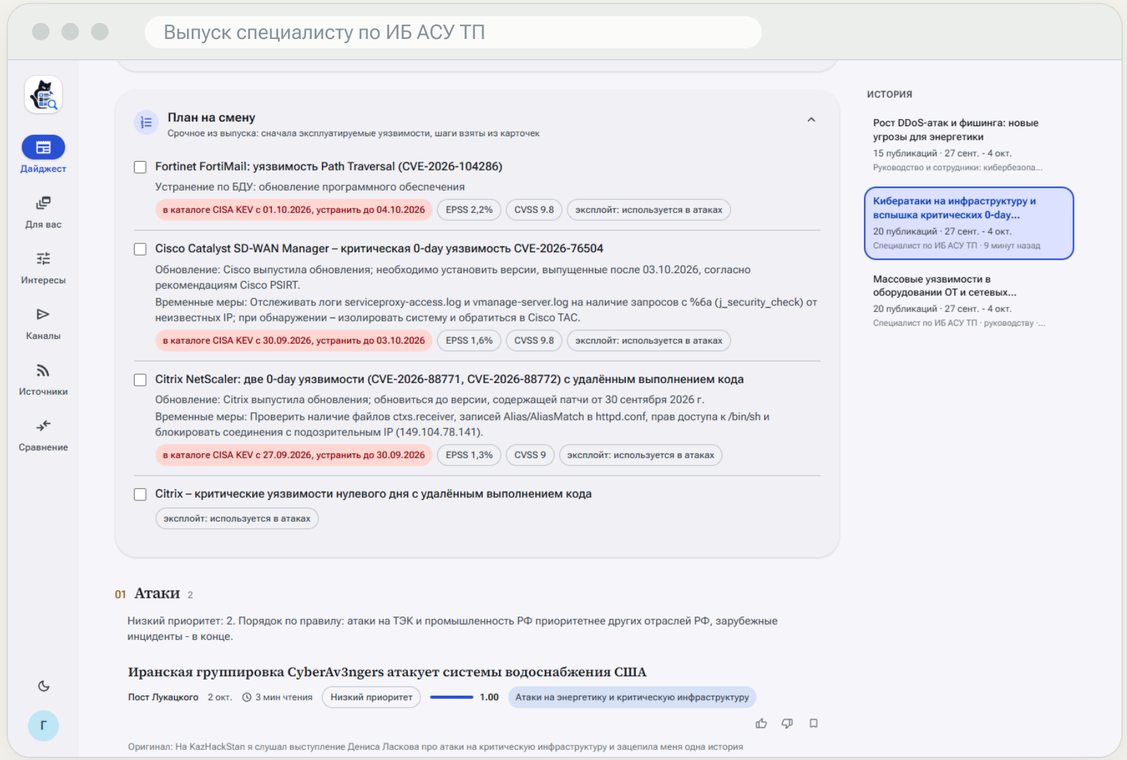
Модель сама вызывает инструмент `lookup_vulnerability`: CISA KEV, БДУ ФСТЭК, NVD, EPSS и Exploit-DB по локальным копиям. Номера, о которых она не спросила, граф проверяет сам.

Сборка - граф LangGraph с чекпоинтами: упавший воркер продолжает с прерванного шага. Ответы модели кешируются, повторная сборка по тому же профилю занимает секунды.

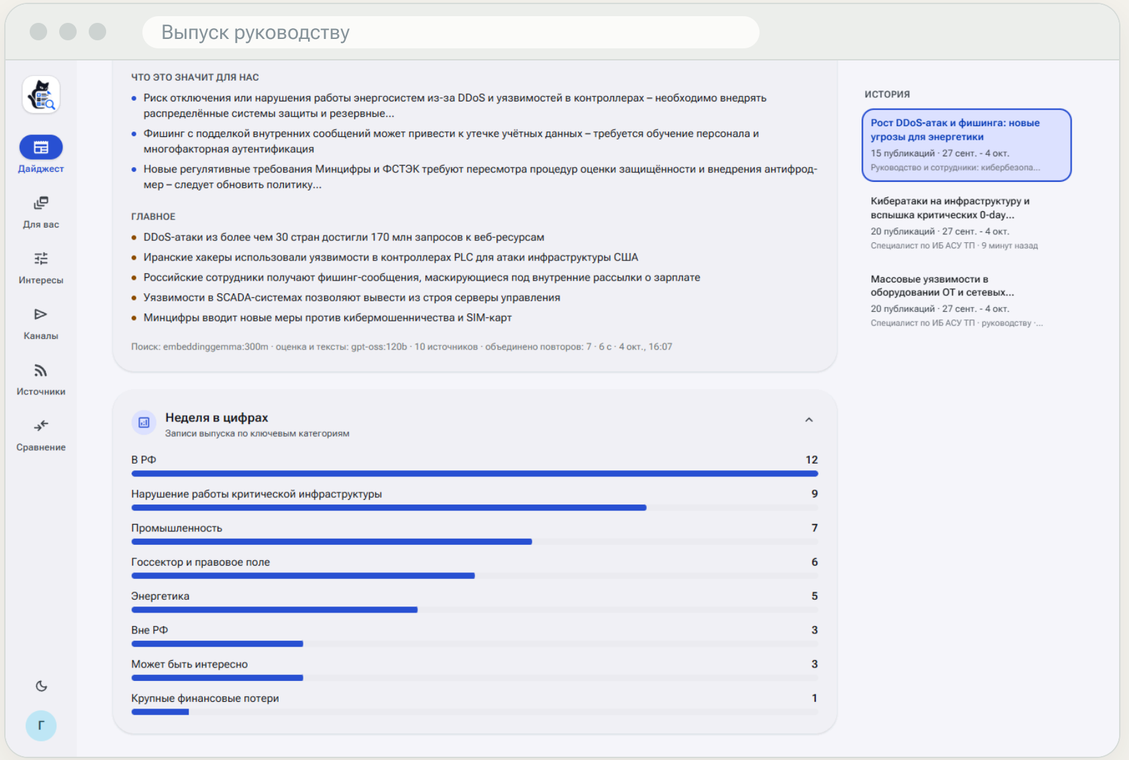


КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

Специалист получает план на смену каждый день, руководство выводы раз в неделю

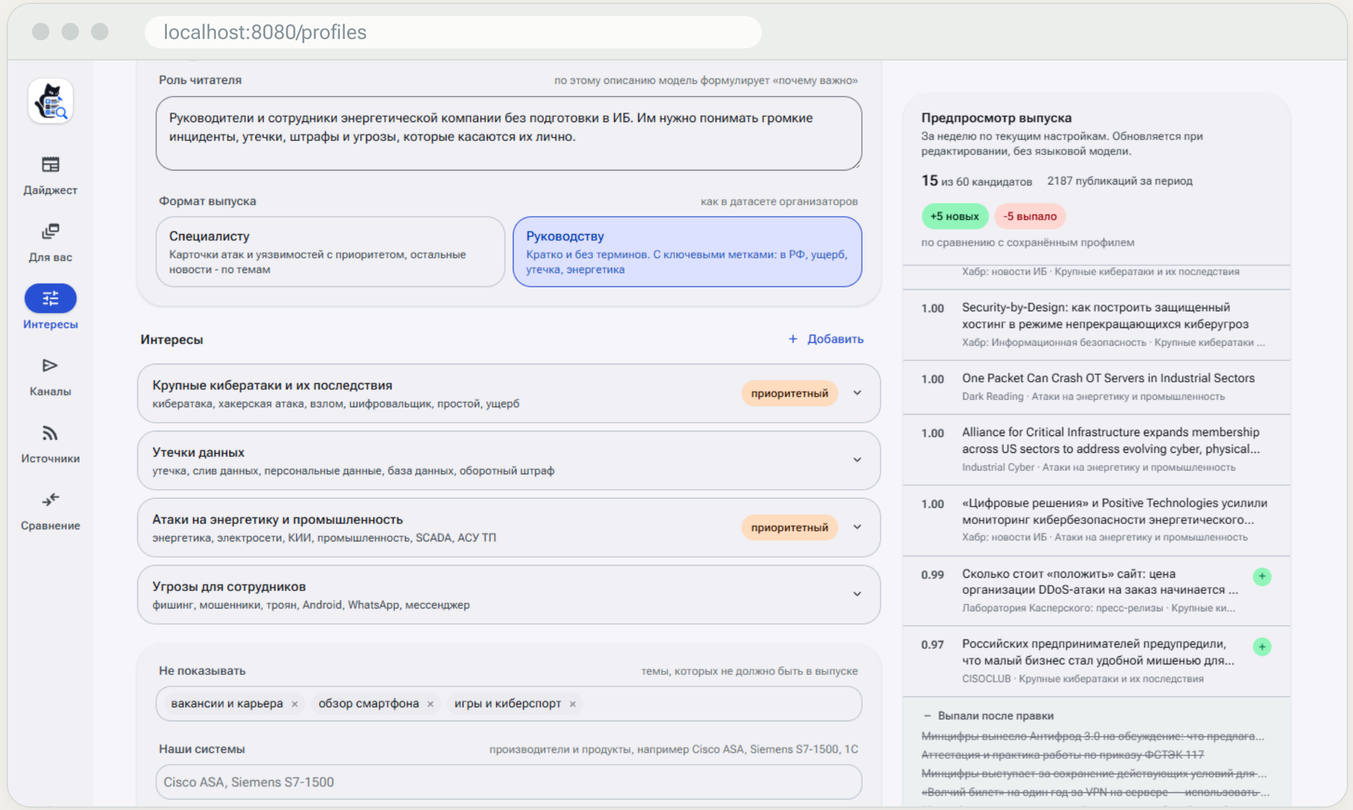


Сначала план на смену: срочные уязвимости и атаки с галочками, что обновить и какие индикаторы искать. Записи о продуктах из «Наших систем» помечены «касается нас».



«Что это значит для нас», период в цифрах против прошлого выпуска, записи в одно-два предложения без номеров CVE и брифинг голосом на две минуты.

Правка интересов сразу меняет подборку, и это видно ещё до сборки



examples/change

Три сценария на одной неделе, выпуск специалисту

Убран интерес «Уязвимости»

20 записей до и после: пришло 9, ушло 9.

Исключение «уязвимости Citrix»

Пришло 3, ушло 3; обе записи о Citrix ушли с причиной.

Порог 0,50 → 0,70, размер 20 → 10

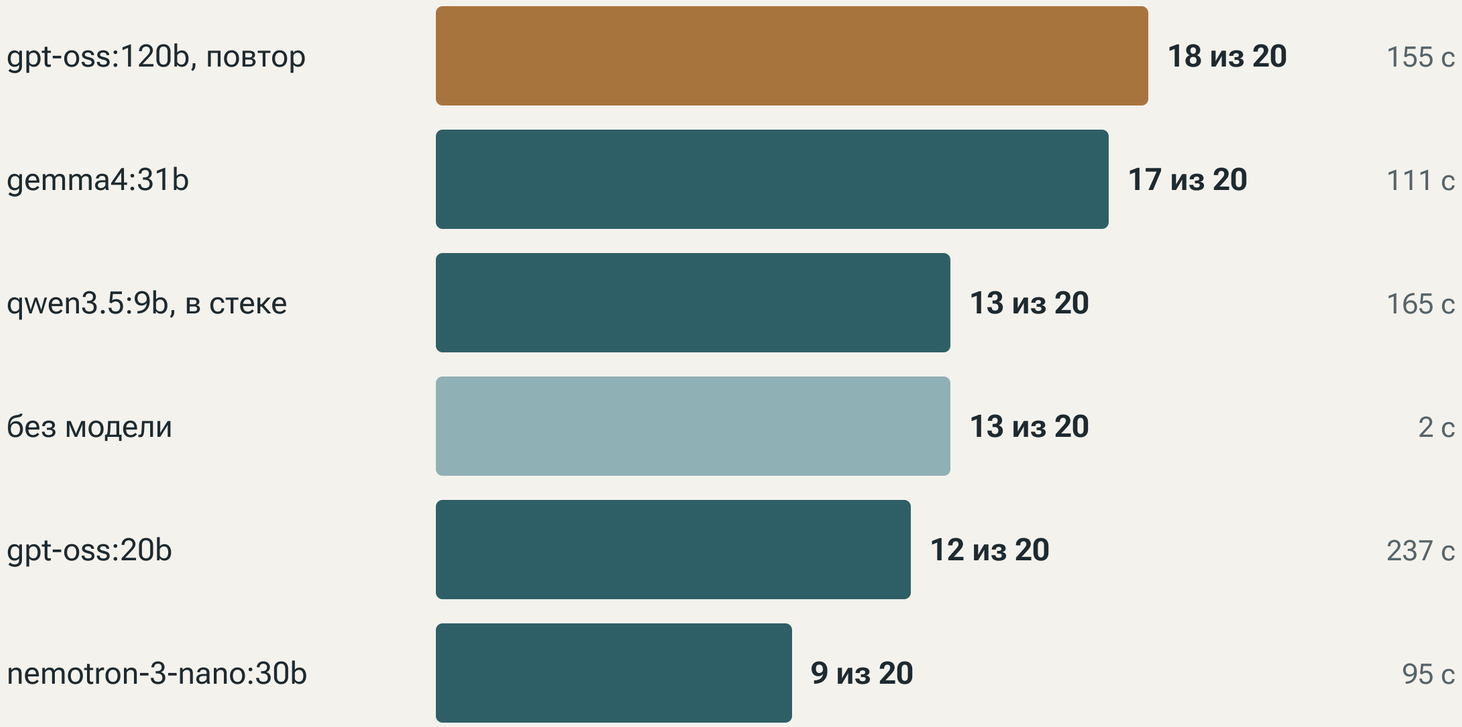
Ушедшие вытеснены более сильными, у каждой её оценка.

Предпросмотр работает без языковой модели, «Сравнение» показывает два выпуска рядом.

КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

Модель меняется одной строкой в .env, сценарий выпуска держится на всех

Записей, совпавших с первым прогоном gpt-oss:120b, из 20, и время сборки



Разделы, карточки, приоритеты и проверка работают на всех моделях и без модели.

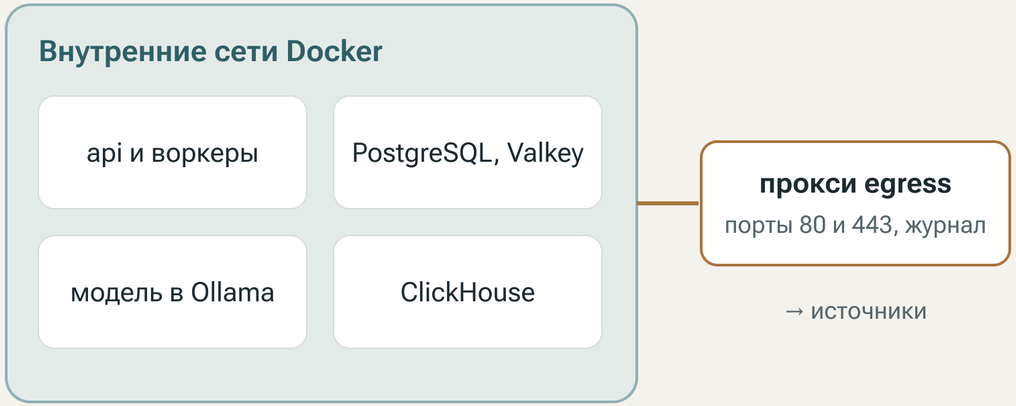
Два прогона одной gpt-oss:120b совпадают в 18 записях из 20: это шум самой модели.

Поддерживаются Ollama и любой OpenAI-совместимый API: Yandex AI Studio, vLLM. По умолчанию в режиме с моделью - локальная Qwen3.6 35B-A3B.

Выпуск специалисту по ИБ АСУ ТП за неделю примеров: 60 кандидатов, 20 записей. examples/models/README.md

КРИТЕРИЙ 2 · ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

Стек работает в закрытом контуре, наружу ходит только загрузчик источников



`offline_bundle.sh save`: 7 образов ядра 4,7 ГБ и модели 1,6 ГБ за 4 мин 21 с. `load` в пустой каталог за 3 мин 29 с, копия поднялась без сети и прошла проверочный сценарий.

Железо: только свои замеры

Конфигурация	Сборка	Выпусков в час
Без языковой модели	0,5 с	тысячи
qwen3.5:9b, RTX 5070 12 ГБ	81-102 с	35-44
qwen3.5:0.8b, процессор ноутбука	731,5 с	4-5
Qwen3.6 35B-A3B, gpt-oss-120b локально	ждут замера на карте NVIDIA	

README, «Закрытый контур» и «Требования к железу».

КРИТЕРИЙ 3 · БИЗНЕС-ОРИЕНТИРОВАННОСТЬ

С ассистентом мониторинг обходится команде в 28 700 ₽ вместо 89 000 ₽ в месяц



60 600 ₽

экономии в месяц на команду из трёх специалистов, **0,73 млн ₽** в год

Выпуск специалисту: 166 511 токенов на вход и 16 127 на выход, около 2,9 ₽. Руководству около 1,9 ₽.

Чтение выпуска остаётся у человека: 15 минут в день заложены в расчёт.

Хабр Карьера; тарифы Ollama на 03.10.2026; курс ЦБ 83,48 ₽; Selectel. docs/BUSINESS.md, «Экономика».

КРИТЕРИЙ 3 · БИЗНЕС-ОРИЕНТИРОВАННОСТЬ

Кроме выпуска сотрудник получает новости в ленте, в Telegram, голосом и через ИИ-ассистента

Лента «Для вас»

Учитывает интересы, резюме и отметки читателя и объясняет, почему статья в ней.

Профиль по резюме

Должность и навыки из резюме дают профиль с первой минуты; имя и контакты вырезаются до анализа.

Каналы в Telegram

Боты публикуют новости по расписанию под аудиторию каждого канала, с черновиками на проверку.

Брифинг голосом

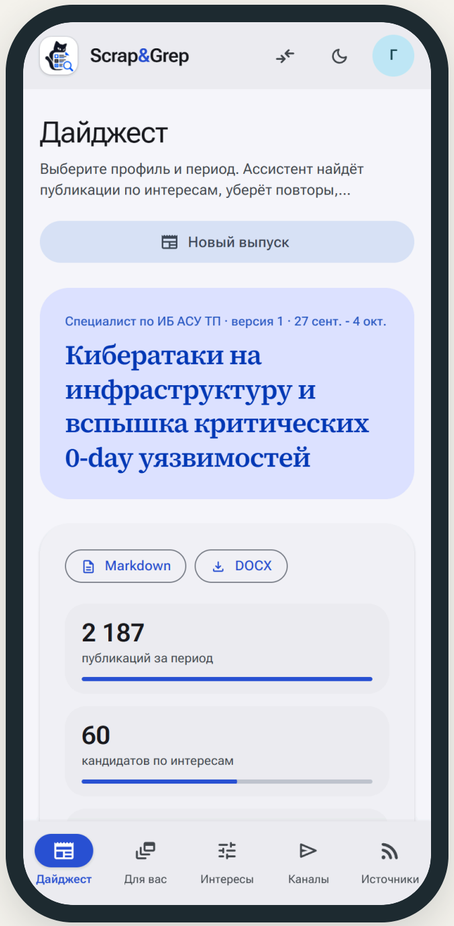
Выпуск руководству пересказывается примерно за две минуты, без номеров уязвимостей.

MCP для ИИ-ассистентов

Claude, Cursor и другие клиенты видят по личному ключу только ленту и выпуски этого читателя.

Аналитика и ранжирование

Показы и отметки пишутся в ClickHouse; модель ранжирования включается, только если обгоняет ручные веса.



ВНЕДРЕНИЕ

Пилот на 4 недели проверит главное число: полноту выпуска против аналитика

Установка

Закрытый контур: образы, веса модели, корпоративный прокси, проверочный сценарий. 10-20 сотрудников из разных групп, у каждого свой профиль.

Что измеряем

Время до готового обзора, полнота против ручной подборки, доля открытых записей и отметок по неделям. События уже пишутся в ClickHouse.

Успех

Полнота выпуска не ниже 90% от того, что нашёл аналитик, при проверке выпуска не дольше 15 минут в день.

Попробовать

```
docker compose up -d --build
```

Интерфейс на localhost:8080, экрана входа нет.

```
docker compose run --rm cli digest
```

Оба выпуска в Markdown и DOCX в папке out/.

Репозиторий: git.codenrock.com/codenrock/ii-assistenty/misis-mojarung/assistent-dlya-sozdaniya-it-ib-daydzhestov

docs/BUSINESS.md, «Пилот»; README, «Быстрый запуск».