

Tail&Grep

ИИ-ассистент, который делает работу аналитика ИБ по новостям: сам собирает, отбирает, ставит приоритет и пишет выпуск

Выпуск специалисту за сутки и руководству за неделю собирается за одну-четыре минуты. Хакатон «ИИ-ассистенты для энергетики», полуфинал. Команда misis-mojarung.

ПРОБЛЕМА

Следить за новостями ИБ сейчас приходится вручную, и это дорого

- Только в списках датасета организаторов 62 источника: 24 сайта и 18 Telegram-каналов для специалистов, 20 сайтов для руководства.
- Часть сайтов не пускает бота: Cloudflare, Akamai, страницы, которые собирает скрипт. БДУ АСУ ТП без браузера пустая.
- Две аудитории читают по-разному: специалисту нужны детали каждый день, руководству - тезисы раз в неделю.
- От того, кто в отпуске, зависят полнота и приоритет: единого правила нет.

≈89 000 ₽

в месяц стоит час мониторинга в день у трёх специалистов: медиана SOC-аналитика 149 000 ₽, с взносами около 1 170 ₽ за час, плюс 3 часа в неделю на сводку руководству.

Хабр Карьера, I полугодие 2026. Часы - допущение, пока их не замерили у аналитика.

ГИПОТЕЗА ЖЮРИ

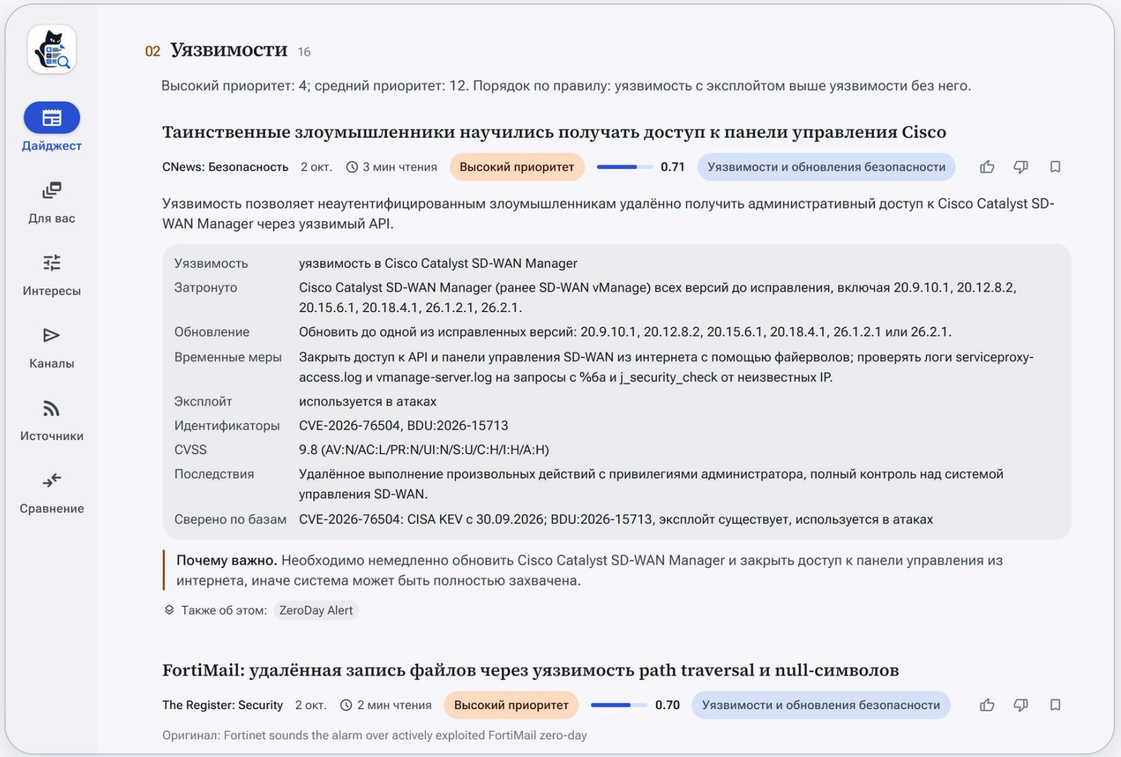
Может ли ассистент заменить аналитика ИБ? Каждый шаг его работы он делает сам

РАБОТА АНАЛИТИКА	ЧТО ДЕЛАЕТ АССИСТЕНТ
Поиск и сбор	87 источников, из списков датасета 61 из 62; сайты без ленты читаются как страницы новостей, защищённые - лестницей способов до браузера в стеке и прокси; любой читатель добавляет любой адрес
Отбор	профиль читателя: интересы, исключения, порог; 60 кандидатов оценивает модель, у каждой записи и у каждого отказа есть причина
Приоритизация	правило датасета: атака на энергетику и промышленность РФ выше всех, уязвимость с эксплойтом выше; эксплойт сверяется с CISA KEV и БДУ ФСТЭК
Подача	два выпуска: специалисту подробно за сутки, руководству тезисно за неделю; Markdown и DOCX, из браузера или одной командой в консоли

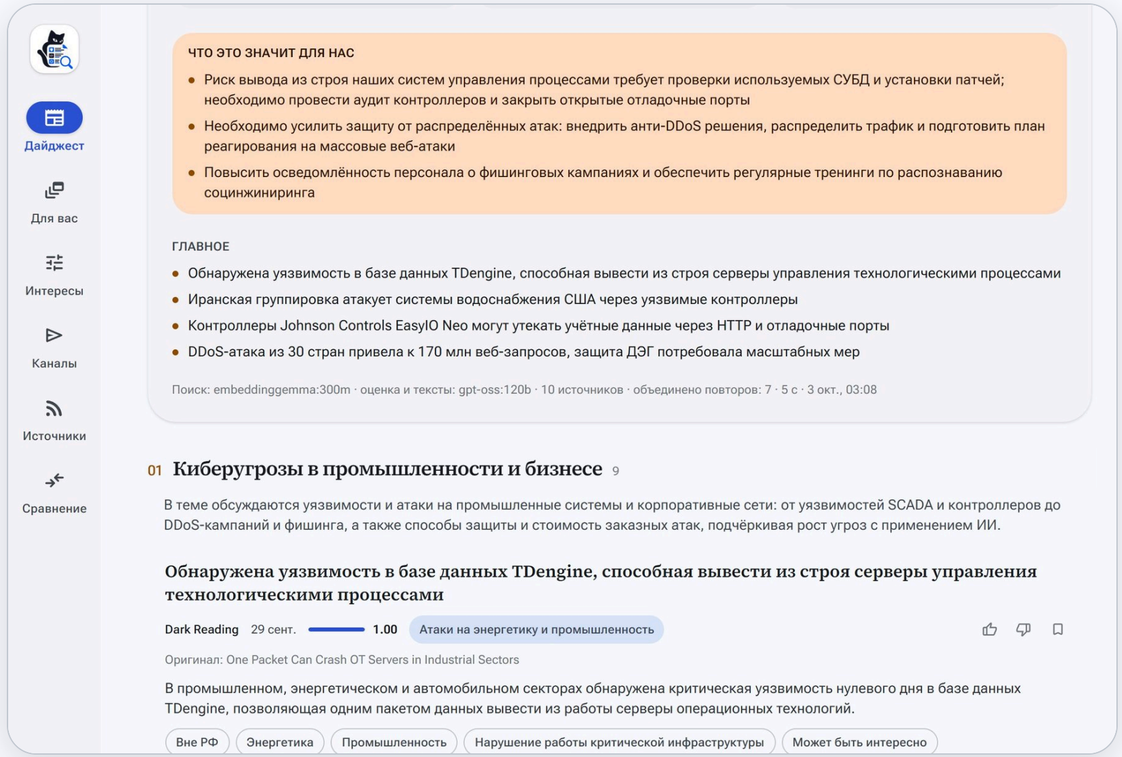
Чего пока нет: сравнения с живым аналитиком на одной неделе. Комплект для него готов, разметки человеком ещё нет, поэтому цифр сравнения мы не приводим.

ДВЕ АУДИТОРИИ

Технарям подробно и каждый день, руководству тезисно и раз в неделю



Специалисту, за сутки атаки и уязвимости карточками, приоритет по правилу датасета, «Сверено по базам»: CISA KEV и БДУ ФСТЭК



Руководству, за неделю «Что это значит для нас», записи в одно-два предложения без номеров CVE и CVSS, двенадцать признаков датасета

Период и расписание по умолчанию берутся от аудитории профиля

КАК РАБОТАЕТ

Граф сборки: от публикации до проверенной записи со ссылкой на первоисточник

Сбор
опрос каждые 15 минут, полный текст со страницы, если в ленте анонс

Поиск
по смыслу и по словам по каждому интересу профиля

Оценка
модель оценивает 60 лучших кандидатов по шкале 0-3 с причиной

Склейка
пересказы одной новости в разных источниках становятся одной записью

Запись
тип, карточка, приоритет, выжимка, «почему важно»

Проверка
чего нет в статье, нет в карточке; номера сверяются с CISA KEV и БДУ

Выпуск
Markdown с YAML и оглавлением, DOCX, история

- Сборка - граф LangGraph с чекпоинтами: если воркер упадёт, выпуск продолжится с прерванного шага.
- Ответы модели кешируются: повторная сборка по тому же профилю занимает секунды.
- Без модели работает автономный режим: поиск, оценка и выжимки без языковой модели.

Веб или консоль

Стек поднимается одной командой, выпуск без браузера - второй:

```
docker compose up -d --build
```

```
docker compose run --rm cli digest --audience specialist
```

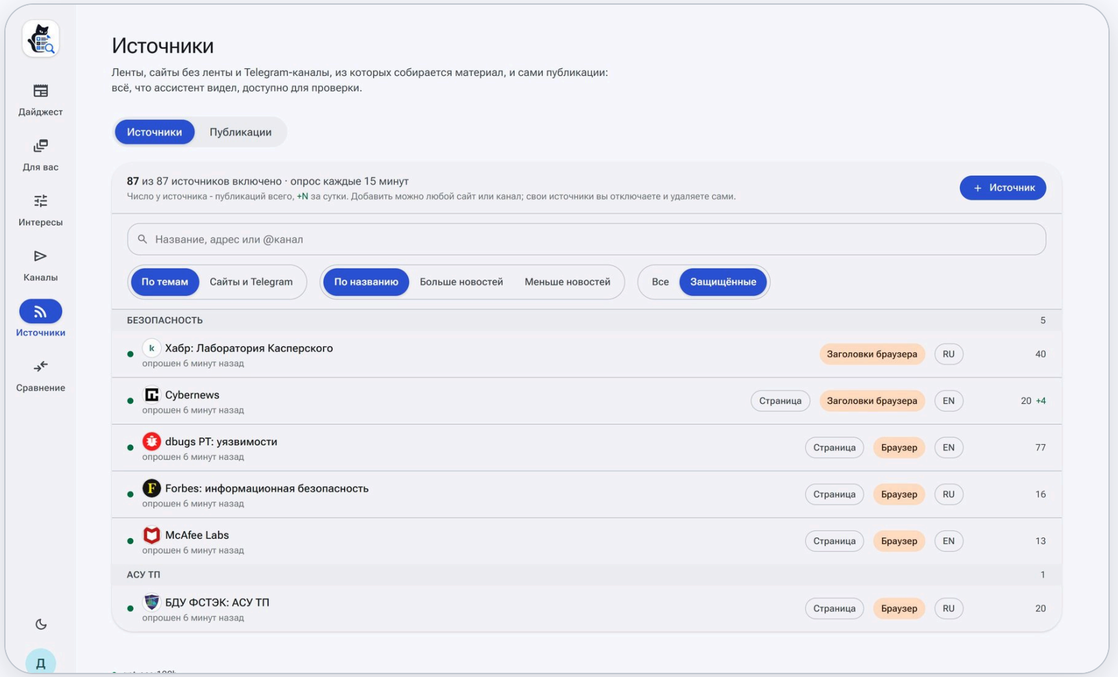
Файлы .md и .docx в out/. Веб открывается без экрана входа.

СБОР

Сайт не пускает бота - ассистент поднимается по лестнице

1. **Обычный запрос**
   SecurityLab, Habr: 0,2-0,7 с
2. **Заголовки браузера**
   Cybernews: 403 и заглушка Cloudflare на шаге 1
3. **TLS-отпечаток Chrome, curl_cffi**
   Netskope, SecurityWeek, Dark Reading: 0,9-4,2 с
4. **Браузер в стеке**
   БДУ АСУ ТП, Forbes, dbugs, McAfee: страницы, которые собирает скрипт
5. **FlareSolverr**
   проверка Cloudflare с JS: 15,9 с

\+ **Прокси**
общий, на источник или пулом с ротацией при 403 и 429



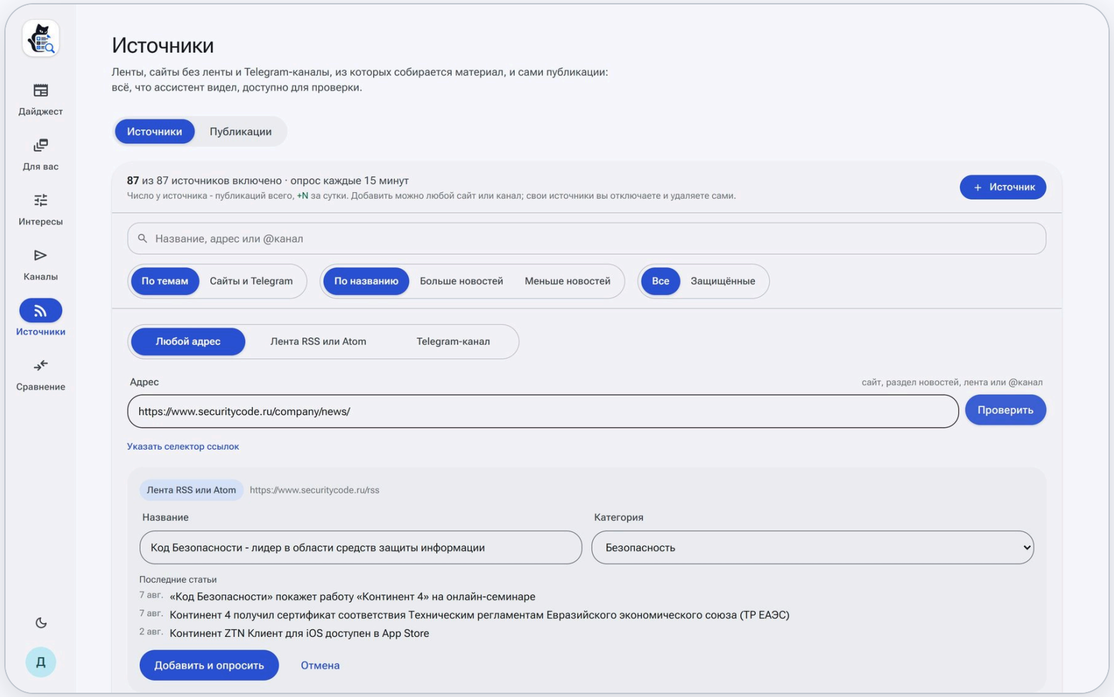
Из списков датасета читалось **42 из 62**, теперь **61 из 62**; Broadcom отдаёт JSON без ссылок на статьи.

Ступень и причина видны у источника. Защита от SSRF работает на каждой ступени.

Время - замеры 2-3 октября 2026, DECISIONS, «Сбор: лестница способов чтения»

любой источник

Не только датасет: любой сайт или канал

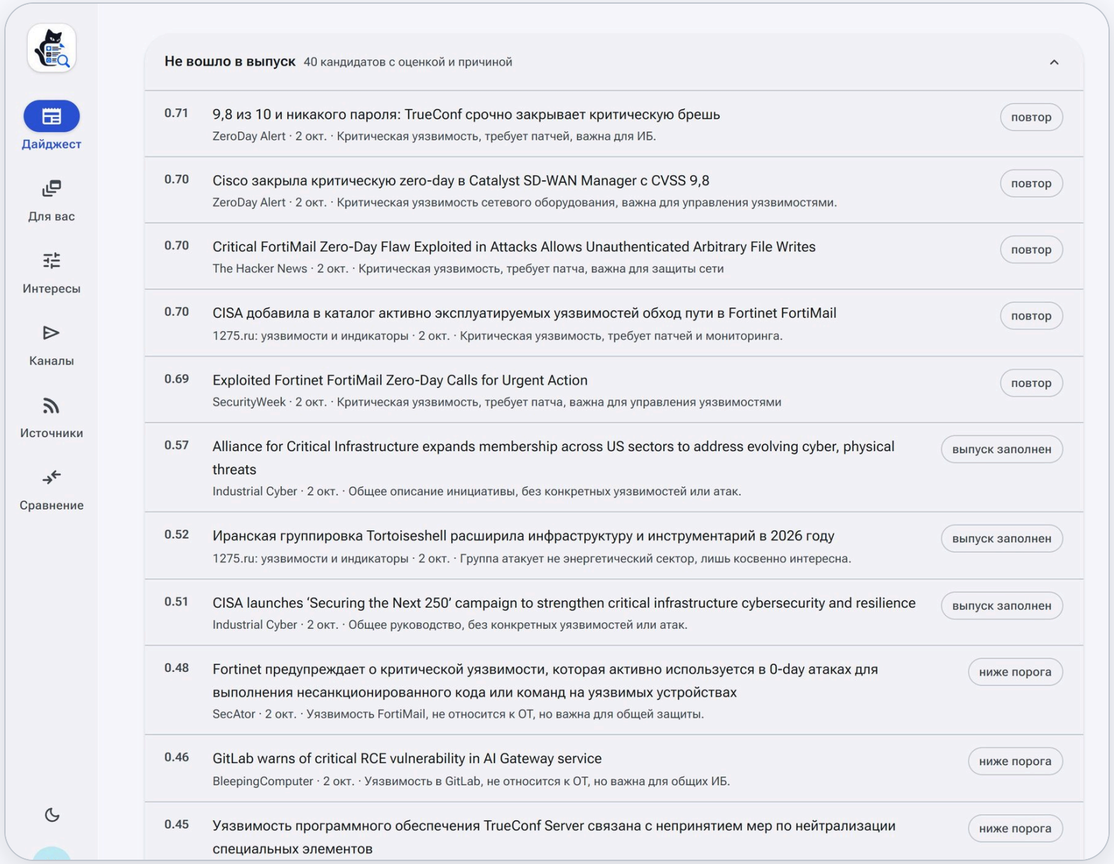


- Читатель вставляет адрес: сайт, раздел новостей, ленту или `@канал`.
- Ассистент сам определяет, что это: лента RSS или Atom, страница новостей без ленты, WordPress API или Telegram-канал.
- До сохранения видно, как сайт читается, и три последние статьи.
- Добавить может любой читатель, менять и удалять - автор и администратор.

На стенде: `securitycode.ru/company/news/` определён как лента за 8,1 с, `t.me/dataleak` как канал за 1,1 с.

ОТБОР И ПРИОРИТИЗАЦИЯ

Каждая запись объяснима и проверена по первоисточнику



- Приоритет по правилу датасета: атака на энергетику и промышленность РФ выше атаки на другие отрасли РФ, за рубежом ниже всех; уязвимость с эксплойтом выше.
- Модель сама вызывает инструмент `lookup_vulnerability`: каталог CISA KEV и БДУ ФСТЭК. Номера, о которых она не спросила, граф проверяет сам.
- Чего нет в тексте статьи, в карточке нет. Индикаторы компрометации и техники MITRE ATT&CK у атаки берутся из самой статьи, вектор CVSS у уязвимости расписан словами.
- «Не вошло в выпуск»: каждый кандидат с оценкой и причиной. Правка интересов сразу видна в предпросмотре и в «Сравнении».

21 пример датасета прогнан через решение: тип записи совпал в 6 из 6, приоритет в 4 из 6.

МОДЕЛИ

Модель меняется в `.env`, код не трогается

МОДЕЛЬ	ГДЕ РАБОТАЕТ	СБОРКА, С	СОВПАЛО С ПЕРВЫМ ПРОГОНОМ
gpt-oss:120b	облако Ollama, стенд и примеры	120	20 из 20
gpt-oss:120b, повтор	облако Ollama	155	18 из 20
gemma4:31b	облако Ollama	111	17 из 20
gpt-oss:20b	облако Ollama	237	12 из 20
nemotron-3-nano:30b	облако Ollama	95	9 из 20
qwen3.5:9b	в стеке, видеокарта 8 ГБ	165	13 из 20
без модели	автономный режим	2	13 из 20

Разделы, карточки, приоритеты и проверка работают на всех. Два прогона одной gpt-oss:120b совпадают в 18 записях из 20 - это шум самой модели. Ollama и OpenAI-совместимый API: Yandex AI Studio, vLLM. По умолчанию в режиме с моделью - локальная Qwen3.6 35B-A3B в Ollama стека.

ЗАКРЫТЫЙ КОНТУР

Всё работает внутри контура, наружу ходит только загрузчик источников

Поставка без интернета

- `offline_bundle.sh save`: 7 образов ядра 4,7 ГБ и модели 1,6 ГБ за 4 мин 21 с.
- `load` в пустой каталог за 3 мин 29 с; копия поднялась без сети, проверочный сценарий прошёл целиком.
- Стек во внутренней сети Docker: соединение наружу из `api` - «Network is unreachable».
- Сбор через корпоративный прокси, модель эмбеддингов в образе.

Железо, свои замеры

КОНФИГУРАЦИЯ	СБОРКА	ВЫПУСКОВ В ЧАС
Без языковой модели	0,5 с	тысячи
qwen3.5:9b, RTX 5070 12 ГБ	81-102 с	35-44
qwen3.5:0.8b на процессоре ноутбука	731,5 с	4-5

Qwen3.6 35B-A3B и gpt-oss-120b локально ждут замера на карте NVIDIA: команда замера готова.

ЭКОНОМИКА

Команда из трёх специалистов экономит около 60 600 ₽ в месяц

89 000 ₽

в месяц стоит ручной мониторинг: час в день у трёх специалистов и сводка руководству. При 30 минутах - 52 000 ₽, при двух часах - 163 000 ₽.

28 700 ₽

в месяц с ассистентом: тариф модели 1 670 ₽, сервер 6 137 ₽, сопровождение 2 350 ₽ и 15 минут в день на чтение выпуска 18 500 ₽.

0,73 млн ₽

в год на одну команду. Вложений на старте нет, окупаемость с первого месяца.

Токены замерены на неделе снимка: выпуск специалисту - 166 511 на вход и 16 127 на выход, около 2,9 ₽; руководству - около 1,9 ₽. Ассистент забирает поиск, отбор, приоритет и сводку; чтение выпуска остаётся у человека.

Хабр Карьера; тарифы Ollama на 03.10.2026; курс ЦБ 83,48 ₽; Selectel. Источник каждой цифры - BUSINESS.md, «Экономика»

ВНЕДРЕНИЕ И ЧТО ДАЛЬШЕ

Пилот проверяет гипотезу числом

Пилот в энергокомпании

- Установка в закрытом контуре: образы, веса модели, корпоративный прокси, проверочный сценарий.
- Специалист ИБ размечает неделю: оценка 0-3, «обязательно в выпуск», приоритет. Комплект и скрипт метрик готовы.
- Успех: полнота выпуска не ниже 90% от того, что нашёл аналитик, при проверке выпуска не дольше 15 минут в день.

К финалу

- Сравнение с аналитиком на одной неделе: время, полнота, ошибки, слепая оценка.
- Модели финала локально: Qwen3.6 35B-A3B, gpt-oss-120b, Alice AI ART.
- Специалистам - техники MITRE ATT&CK и индикаторы компрометации в карточке атаки.
- Доставка выпуска на корпоративную почту.

Попробовать

```
docker compose up -d --build
```

Интерфейс на localhost:8080, консоль - `docker compose run --rm cli digest`, примеры выпусков - examples/. Репозиторий: git.codenrock.com/codenrock/ii-assistenty/misis-mojarung/assistent-dlya-sozdaniya-it-ib-daydzhestov